

AICarRacing 종합 기술 보고서

2-Action PPO: 붕괴 복구 · 장애물 회피 · 2 vs 3 Action 대조

팀 B

2026-06-15

- [AICarRacing 종합 기술 보고서](#)
- [Part 0 — 실행 환경 · 문제 정의\(State/Reward\) · 알고리즘](#)
 - [0. 실행 환경 및 설치 \(재현성\)](#)
 - [1. 문제 및 환경 정의](#)
 - [1-A. State\(상태\) 정의](#)
 - [1-B. Reward\(보상\) 정의](#)
 - [2. 강화학습 알고리즘 — PPO 이론](#)
- [Part I — 베이스 복구 · 스케일업 · 장애물 round-1](#)
 - [1. 개요 / 목표](#)
 - [2. 시스템 구성](#)
 - [3. 문제 진단 및 해결 \(기술적 핵심\)](#)
 - [4. 실험 결과](#)
 - [5. 장애물 환경 설계 \(CarRacingObstacles-v0 \)](#)
 - [6. 코너 감속 개선](#)
 - [9. 부록](#)
- [Part II — 장애물 심화 실험 \(진단 · 크기 · 엔트로피 · 2 vs 3 action\)](#)
 - [2. 환경 설계 — CarRacingObstacles-v0](#)
 - [4. 장애물 크기 실험 \(소형 vs 대형\)](#)
 - [5. 진단 — “급커브 이탈”은 오진이었다 \(계측 평가\)](#)
 - [6. 실험 결과 종합](#)
 - [7. 마지막 실험 — 행동 노이즈 축소\(ent coef \)는 비\(非\)레버였다](#)
 - [8. 3-action 대조 실험 — 2 vs 3 action \(native gas/brake\)](#)
 - [핵심 교훈 \(종합\)](#)
 - [구현 산출물 \(커밋 안 함\)](#)
 - [부록 — 재현 커맨드](#)
- [부록 A — 엔지니어링 노트 \(버그 수정\)](#)
 - [A. 환경 구축 시 해결한 버그 \(엔지니어링 핵심\)](#)
- [부록 Z — 그림 · 영상\(GIF\) 인덱스](#)
 - [Z.1 생성 그림 \(figures\)](#)
 - [Z.2 주행 프레임 \(정지 컷\)](#)

- [Z.3 애니메이션 GIF \(별도 첨부\)](#)

AlCarRacing 종합 기술 보고서

2-Action PPO 에이전트: 붕괴 복구 → 장애물 회피 확장 → 2 vs 3 Action 대조 실험

팀 B · 2026-06-15 · 환경: Gymnasium CarRacing-v3 / CarRacingObstacles-v0

본 문서는 채점 루브릭 순서를 따른다. **Part 0**(실행 환경·설치 / 문제·State·Reward 정의 / PPO 이론) → **Part I**(붕괴 복구 + 베이스 스케일업 + 장애물 round-1) → **Part II**(장애물 심화: 진단·크기·엔트로피·**2 vs 3 action** 대조) → 부록(그림·GIF). 표는 원문 그대로, 그림·주행 프레임은 관련 절에 삽입했다.

Part 0 — 실행 환경 · 문제 정의(State/Reward) · 알고리즘

0. 실행 환경 및 설치 (재현성)

본 프로젝트는 학습과 평가/녹화를 서로 다른 환경에서 수행한다. 무거운 PPO 학습은 원격 A100 GPU 서버(conda 환경 `teamB_env`, CUDA 빌드 PyTorch)에서, 학습이 끝난 체크포인트의 평가·영상 녹화는 로컬 macOS(conda 환경 `racing`, CPU)에서 진행했다. 아래 버전은 로컬 `racing` 환경에서 `importlib.metadata` 로 실측한 값이며, 채점 환경 재현 시 그대로 맞추면 된다.

0.1 사용 환경 / 버전

구분	패키지 / 항목	버전	용도
공통	Python	3.11.15	인터프리터
학습(원격)	환경	conda <code>teamB_env</code> / A100 CUDA	PPO 학습 (GPU)
평가·녹화(로컬)	환경	conda <code>racing</code> / macOS CPU	체크포인트 평가, mp4 녹화
딥러닝	torch	2.12.0 (로컬 CPU 빌드)	학습/추론 — 원격 학습 은 <code>teamB_env</code> 의 CUDA 빌드 torch 사용
강화학습	gymnasium	1.3.0	환경 API (CarRacing)
물리엔진	box2d-py	2.3.8	CarRacing/Box2D 물 리 (<code>gymnasium[box2d]</code> 가 끌어옴)
렌더링	pygame	2.6.1	환경 렌더링 (<code>gymnasium[box2d]</code> 가 끌어옴)
영상 전처리	opencv-python (cv2)	4.x	grayscale 변환 (<code>src/env_wrappers.py</code> 의 <code>import cv2</code>) — 필 수
수치연산	numpy	2.4.6	배열 연산
녹화	imageio / imageio-ffmpeg	2.37.3 / 0.6.0	mp4 영상 저장
로깅·시각화	tensorboard / matplotlib	2.20.0 / 3.10.9	학습 곡선, 그림

제출물에 `requirements.txt` 를 동봉했다(`pip install -r requirements.txt`). 아래는 그 내용을 풀어 쓴 것이다.

0.2 설치 (기존 실습 docker image에 추가 설치)

기존 실습용 docker base image를 그대로 사용하되, 아래 pip 패키지만 추가로 설치하면 된다.

복붙용 한 줄(권장):

```
pip install "torch>=2.6" "gymnasium[box2d]==1.3.0" opencv-python numpy==2.4.6 imageio==2.37.3
imageio-ffmpeg==0.6.0 tensorboard==2.20.0 matplotlib==3.10.9
```

개별 줄(필요한 것만 골라 설치):

```
# base 이미지에 PyTorch가 이미 있으면 아래 torch 줄은 건너뛰다.
# (단, 체크포인트 로드엔 torch>=2.6 필요 - 0.4 참조)
pip install "torch>=2.6"

pip install "gymnasium[box2d]==1.3.0" # CarRacing 환경 + Box2D 물리 + pygame(렌더링)을 함께 끌어옴
pip install opencv-python # ★ 필수: src/env_wrappers.py 의 cv2 (없으면 모든 스크립트가
import 단계에서 ModuleNotFoundError: cv2)
pip install numpy==2.4.6
pip install imageio==2.37.3 imageio-ffmpeg==0.6.0 # mp4 녹화(record_video.py)
pip install tensorboard==2.20.0 matplotlib==3.10.9 # 로깅 / 그림
```

각주 (Box2D 설치): `gymnasium[box2d]` 는 `box2d-py` (본 환경 2.3.8)와 `pygame` 을 함께 설치한다. extras 설치가 실패하면 `pip install box2d-py pygame` 로 직접 설치할 수 있다. 일부 환경에서는 C++ 바인딩 빌드를 위해 `swig` 가 필요하다(예: `apt-get install -y swig` 또는 `conda install -c conda-forge swig` 후 재시도). `pygame` 을 별도 버전으로 핀하면 `gymnasium` 이 요구하는 버전과 충돌할 수 있으니 가급적 `gymnasium[box2d]` 가 끌어오게 둔다.

0.3 실행 커맨드 (학습 / 평가 / 영상)

모든 스크립트는 **모듈 방식**(`python -m scripts.NAME`)으로 실행한다(패키지 상대 import 해석을 위함). 저장소 루트에서 실행할 것.

```
# --- 학습 (원격 A100 / teamB_env 권장) ---
# 베이스(장애물 없음)
python -m scripts.train_ppo_2action2 --steps 6000000

# 장애물 학습 (2-action)
```

```
python -m scripts.train_ppo_2action_obstacles \
    --accel-turn-weight 0.2 --obstacle-size-min 0.25 --obstacle-size-max 0.6

# 3-action 대조군
python -m scripts.train_ppo_3action_obstacles \
    --ent-coef 0.003 --obstacle-size-min 0.25 --obstacle-size-max 0.6

# --- 평가 (로컬 macOS / racing) ---
# 베이스
python -m scripts.evaluate_agent_2action \
    --model ./models/ppo_2action4/best_model.pth --episodes 100 --seed 42

# 장애물 (동봉 체크포인트: models/obs_small/best_model.pth)
python -m scripts.evaluate_agent_2action_obstacles \
    --model ./models/obs_small/best_model.pth \
    --obstacle-size-min 0.25 --obstacle-size-max 0.6 --episodes 50 --seed 42

# --- 영상 녹화 (mp4) ---
python scripts/record_video.py --model ./models/ppo_2action4/best_model.pth --episodes 5
```

장애물 환경 자동 등록: 장애물 관련 스크립트는 `import src.car_racing_obstacles` 시점에 `gym.register(id="CarRacingObstacles-v0", ...)` 가 자동 실행되므로(`src/car_racing_obstacles.py`), 별도 등록 절차 없이 `gym.make("CarRacingObstacles-v0", ...)` 가 동작한다.

torch 버전 요구: 평가/녹화 스크립트는 체크포인트를 `torch.load(..., weights_only=False)` 로 로드한다 (체크포인트에 numpy 스칼라 등이 포함되어 있어 `weights_only=True` 로는 로드 불가). 이 인자 기본값 변경 때문에 **torch>=2.6** 이 필요하다.

0.4 디렉토리 / 체크포인트 경로 관례 및 가용성 (중요)

체크포인트는 실행(run)별로 `./models/<run_name>/best_model.pth` 에 저장되며, 학습 로그는 `./logs/` , 녹화 영상은 `./videos*/` 에 위치한다.

채점자 주의 — 체크포인트 입수: `.gitignore` 에 `/models` 가 있어 학습된 체크포인트는 git에 포함되지 않는다. 제출 번들에 핵심 평가용 체크포인트를 별도 동봉했다:

모델	경로	clean 성능	비고
2-action 베이스(최종)	<code>models/ppo_2action4/best_model.pth</code>	667 / 745	무장애물
2-action 장애물	<code>models/obs_small/best_model.pth</code>	365 / 325	위 평가 명령이 이 파일을 가리킴

모델	경로	clean 성능	비고
3-action 베이스(참고)	BestSavedAgents/evaluated641.pth	~675(임베디드)	git 추적본

보고서에 등장하는 최고 2-action 장애물 모델(obs_small_p02 , clean 415)와 3-action 장애물 모델 (obs_3action_lowent , clean 229)은 원격 학습 서버에만 존재하여 번들에서 제외했다(용량/접근). 이 수치들은 8·장애물 보고서에 기록돼 있으며, 위 학습 커맨드(0.3)로 재현 가능하다.

1. 문제 및 환경 정의

본 프로젝트가 선택한 환경은 Gymnasium CarRacing-v3 (연속 제어, top-down 레이싱)이며, 이를 상속해 무작위 정적 장애물 회피 과제(CarRacingObstacles-v0)를 직접 정의해 확장했다. 목표는 (1) 픽셀 관측만으로 트랙을 빠르고 안정적으로 주행하는 2-action PPO 에이전트를 학습하고, (2) 도로 위 장애물을 회피하도록 일반화하며, (3) 2-action([steering, throttle])과 native 3-action([steering, gas, brake]) 행동 파라미터화를 동일 조건에서 비교하는 것이다. 강화학습의 핵심인 상태(State)와 보상(Reward) 정의를 아래에 상세히 기술한다.

1-A. State(상태) 정의

본 에이전트의 상태(state)는 게임 화면의 픽셀(이미지)이다. 즉 차량 좌표·속도·각도 같은 저차원 수치 벡터가 아니라, 환경이 매 스텝 렌더링한 톱다운(top-down) 화면을 그대로 정책 네트워크의 입력으로 사용하는 순수 픽셀 기반(vision-only) 상태다. 아래에서 원시 관측이 정책 입력 텐서가 되기까지의 전처리 파이프라인과, 장애물 환경에서 상태에 추가되는 정보, 그리고 학습에 쓰는 상태와 화면 표시용 화면의 차이를 코드 근거와 함께 정의한다.

상태 전처리 파이프라인

원시 관측 → grayscale → FrameStack(4) → 정책 입력 (4, 96, 96) → /255 정규화의 순서로 변환되며, 각 단계는 gym Wrapper로 구현되어 환경 생성 시 다음 순서로 합성된다(예:

scripts/train_ppo_2action_obstacles.py:117-120).

```
env = ActionWrapper(env) # 행동 좌표계 변환 (상태 아님 - 아래 참고)
env = GrayScaleObservation(env) # RGB(96,96,3) -> Gray(96,96)
env = TimeLimit(env, max_episode_steps=max_episode_steps)
env = FrameStack(env, frame_stack)# Gray(96,96) -> (4,96,96)
```

단계	입력 shape	출력 shape	근거 (file:line)
원시 관측 (state_pixels)	—	(96, 96, 3) uint8 RGB	car_racing_obstacles.py:133 (self._render("state_pixels"))
GrayScaleObservation	(96, 96, 3)	(96, 96) uint8	env_wrappers.py:22-23, 28

단계	입력 shape	출력 shape	근거 (file:line)
FrameStack(k=4)	(96, 96)	(4, 96, 96) uint8	env_wrappers.py:95, 119-123
정책 입력 정규화	(B, 4, 96, 96) uint8	[0,1] float	cnn_model.py:98

- 원시 관측 — 96×96 state_pixels**. 기본 환경의 관측은 96×96 해상도의 RGB 화면이다. 장애물 환경에서는 `reset()` 이 장애물 생성 직후 `self._render("state_pixels")` 로 첫 관측을 다시 렌더링해 0프레임부터 장애물이 보이도록 보장한다(`car_racing_obstacles.py:131-134`).
- Grayscale 변환**. `GrayScaleObservation` 이 RGB (H,W,3) 를 OpenCV `cv2.cvtColor(..., COLOR_RGB2GRAY)` 로 단일 채널 (H,W) uint8로 축소한다(`env_wrappers.py:25-29`). 관측 공간도 `Box(low=0, high=255, shape=(96,96), dtype=uint8)` 로 갱신된다(`env_wrappers.py:22-23`). 채널 수를 1/3로 줄여 입력 차원을 낮추는 동시에, 뒤이은 `FrameStack`의 채널 축을 “시간(프레임)” 전용으로 비워 둔다.
- FrameStack(4) — 시간 정보 주입**. `FrameStack` 은 최근 `k=4` 개의 그레이스케일 프레임을 `deque(maxlen=k)` 에 모아 `np.stack(..., axis=0)` 로 채널 축에 쌓는다(`env_wrappers.py:88, 101-104, 119-123`). 그 결과 정책에 들어가는 단일 상태 텐서는 (4, 96, 96) 이 된다(관측 공간 (k,)+(H,W) , `env_wrappers.py:95`). 단일 정지 프레임만으로는 차량의 속도·진행 방향 같은 동역학을 추론할 수 없기 때문에, 연속 4프레임을 함께 제공해 CNN이 프레임 간 차이로 운동 정보를 복원하도록 한다(클래스 docstring `env_wrappers.py:70-72`). `reset()` 시에는 첫 관측을 4번 복제해 버퍼를 채운다(`env_wrappers.py:113-117`).
- /255 정규화**. uint8 [0,255] 상태는 CNN 특징 추출기 내부에서 `observations.float() / 255.0` 로 [0,1] 로 정규화된 뒤 합성곱 층에 들어간다(`cnn_model.py:96-98`). 정규화가 환경 Wrapper가 아니라 모델 `forward` 내부에서 일어나므로, 리플레이/버퍼에는 메모리 효율이 좋은 uint8 그대로 저장하고 정규화는 순전파 시점에 1회 수행된다(`ppo_agent_2.py:289, 376, 493` 주석 “normalization inside extractor”). 더미 `forward`로 `flatten` 크기를 썰 때도 동일하게 /255.0 를 적용한다(`cnn_model.py:73`). 첫 합성곱의 입력 채널 수는 관측 공간의 0번째 축, 즉 스택 프레임 수(`n_input_channels = observation_space.shape[0] = 4`)로 설정된다(`cnn_model.py:49, 53`).

요약하면 정책이 보는 상태 텐서는 (4, 96, 96) 의 그레이스케일 프레임 스택이며, [0,1] 로 정규화된 픽셀 강도 값이다.

학습용 상태(state_pixels) vs 화면 표시용(rgb_array)

상태로 쓰는 관측과 사람이 보기 위한 영상은 별개다.

- 학습/평가 입력**은 위의 96×96 `state_pixels` 관측이다. 학습·평가는 `render_mode=None` 으로 환경을 만들고(`train_ppo_2action_obstacles.py:101, evaluate_agent_2action_obstacles.py:52` 의 `"render_mode": None`), 관측은 내부적으로 `state_pixels` 로 렌더된 96×96 프레임을 사용한다(`car_racing_obstacles.py:133`).

- **표시/녹화용**은 `render_mode="rgb_array"` 로 생성한 고해상도(400×600) 화면이다. 영상 녹화 스크립트만이 모드를 쓰며(`record_video.py:316` 의 `render_mode="rgb_array"`), 그 docstring은 “*render mode does not affect the physics, track ... compared to the render_mode=None evaluation run*”라고 명시한다(`record_video.py:95-98`). 즉 표시 화면은 보기 좋은 큰 프레임일 뿐 **에이전트의 상태가 아니며**, 정책 입력에 쓰이는 것은 어디까지나 96×96 `state_pixels` 다. 두 경로 모두 동일한 Wrapper 스택(GrayScale → TimeLimit → FrameStack)을 적용한다(`record_video.py:124-126`).

장애물 환경에서의 상태 — 흰색 quad가 상태에 들어가는 이유

장애물 환경의 핵심 설계는, 장애물을 관측 픽셀 안에 **흰색(255)**으로 그려 넣어 픽셀 기반 에이전트가 인지 가능하게 만든 점이다. 각 장애물은 실제 Box2D 정적 물체(`CreateStaticBody`)인 동시에(`car_racing_obstacles.py:188-194`), 그 사각형 quad가 `self.road_poly` 에 (`quad, OBSTACLE_COLOR`)로 추가되어 렌더 프레임에 그려진다(`car_racing_obstacles.py:196-203`).

이것이 중요한 이유는 **에이전트의 유일한 입력이 픽셀이기 때문이다**. 물리 충돌만 존재하고 화면에 그려지지 않으면, 상태(이미지)에는 장애물이 전혀 나타나지 않아 에이전트가 회피를 학습할 단서가 없다. 모듈 docstring이 이를 명시한다: “*the agent’s input is pixels: the obstacle must be visible in the 96x96 observation to be avoidable*”(`car_racing_obstacles.py:7-9`).

색을 흰색으로 고른 것도 상태 가시성 때문이다. 그레이스케일 변환 후 도로는 약 102, 잔디는 약 162인데 장애물은 255가 되어 **가장 강한 대비**로 부각된다(`car_racing_obstacles.py:9-10`, 35-36 의 `OBSTACLE_COLOR = (255, 255, 255)`). 정규화 후에도 장애물 픽셀은 1.0, 도로는 약 0.4로 분리되어 CNN이 쉽게 식별한다. 또한 장애물 배치는 `self.np_random` 을 사용해 시드별로 재현 가능하므로(`car_racing_obstacles.py:14, 175, 182`), 동일 시드에서 동일한 상태 분포가 보장된다.

행동 좌표계는 상태가 아님 (별도 절 참고)

`ActionWrapper` 는 정책이 출력하는 2차원 행동 [steering, throttle] 을 환경 네이티브 3차원 행동 [steering, gas, brake] 로 변환한다(`throttle>0` 이면 gas, `throttle<0` 이면 brake; `env_wrappers.py:124-142`). 이는 **상태가 아니라 행동(action) 좌표계** 변환이며 상태 정의에는 영향을 주지 않는다 — 자세한 행동 공간 설계는 별도 절에서 다룬다.

1-B. Reward(보상) 정의

본 절은 학습/평가에 사용된 보상 신호를 세 층(layer)으로 나누어 정의한다. (1) 네이티브 CarRacing 보상, (2) 장애물 충돌 패널티, (3) 학습 전용 reward shaping. 모든 수식과 가중치는 실제 코드에서 그대로 인용했다.

보상 신호의 3개 층 구조

```
최종 step reward
= [네이티브 CarRacing 보상]          ← 항상 적용 (학습/평가 공통)
```


+ [장애물 충돌 패널티]

← 장애물 환경에서만 적용 (학습/평가 공통)

+ [reward shaping 항들]

← 학습 시에만 적용, 평가 시 제거

핵심 구분 — shaped reward vs clean reward - shaped reward (학습 시): 위 3개 층을 모두 합산한 값. 에이전트가 실제로 받는 학습 신호이며, 속도/이탈/조향 등 행동 유도 항이 포함된다. shaping wrapper는 학습 스크립트에서 `use_reward_shaping=True` 일 때만 환경에 부착된다 (`scripts/train_ppo_2action_obstacles.py:109-115`).

- clean reward (평가 시): shaping을 제거하고 **네이티브 보상 + 장애물 패널티만** 합산한 값. 보고서의 결과 수치 (베이스 트랙 667점, 장애물 환경 415점 등)는 모두 이 **clean reward** 기준이다. shaping 항(특히 velocity 보상)은 점수를 인위적으로 부풀리므로, 모델 간/환경 간 비교는 반드시 네이티브 척도로만 수행했다.

(1) 네이티브 CarRacing 보상 (gymnasium `car_racing`)

학습/평가 양쪽에서 항상 적용되는 원본 환경 보상이다. (gymnasium 설치본

`gymnasium/envs/box2d/car_racing.py` 기준)

항목	수식 / 값	적용 조건	file:line
프레임 패널티	<code>reward -= 0.1</code> (스텝당 -0.1)	<code>action is not None</code> 인 모든 스텝	<code>car_racing.py:568</code>
타일 통과 보상	<code>reward += 1000.0 / len(track)</code> (= +1000/N, N=총 타일 수)	새 트랙 타일을 처음 통과할 때마다	<code>car_racing.py:92</code>
플레이필드 이탈	<code>step_reward = -100 + 에피소드 종료 (terminated=True)</code>	<code>abs(x) > PLAYFIELD</code> or <code>abs(y) > PLAYFIELD</code>	<code>car_racing.py:579-582</code>
랩 완주	(보상 없음) + 에피소드 종료	모든 타일 통과 또는 새 랩	<code>car_racing.py:574-577</code>

설계 의미: 매 프레임 -0.1이 부과되므로 빨리 완주할수록 점수가 높다. 트랙 N개 타일을 모두 통과하면 누적 +1000, 732프레임에 완주 시 $1000 - 0.1 \times 732 = 926.8$ 이 만점에 가까운 기준값이다 (`car_racing.py:140-141` docstring). 단, 플레이필드 이탈은 -100 + 즉시 사망이라 가장 큰 패널티다.

(2) 장애물 충돌 패널티 (`src/car_racing_obstacles.py`)

네이티브 환경을 상속한 장애물 변형 환경의 추가 패널티. 학습/평가 공통으로 적용되며, **penalty-only 설계**(충돌 해도 에피소드를 종료시키지 않음)다.

항목	수식 / 값	적용 조건	file:line
충돌 패널티	<code>step_reward -= obstacle_penalty</code> (기본 <code>obstacle_penalty=15.0</code> → 스텝당 -15)	해당 스텝에 새 car↔obstacle 접촉이 시작되고 <code>action is not None</code>	<code>src/car_racing_obstacles.py:144-145</code> , 기본값 :87
스텝당 1회 한정	<code>hits</code> 여러 번이어도 패널티는 1회만 차감	한 충돌이 <code>hull+wheel</code> 동시 접촉을 일으켜 과패널티되는 것 방지	<code>src/car_racing_obstacles.py:140-146</code>
비종료	<code>terminated</code> 변경 없음 (<code>super().step</code> 결과 그대로)	항상 (penalty-only)	<code>src/car_racing_obstacles.py:13</code> , :137-148

충돌 검출은 `ObstacleFrictionDetector.BeginContact` 가 장애물 접촉마다 `obstacle_hits_pending += 1` 로 카운트하고(`src/car_racing_obstacles.py:49-53`), `step()` 에서 그 값을 읽어 0보다 크면 한 번만 -15를 차감하는 구조다. 패널티 기본값과 장애물 수(`n_obstacles=10`)는 학습 config에서 지정한다(`scripts/train_ppo_2action_obstacles.py:22-23`).

(3) 학습 전용 Reward Shaping (`RewardShapingWrapper`)

`RewardShapingWrapper` 는 두 학습 스크립트에 인라인으로 정의되어 있다(`scripts/train_ppo_2action_obstacles.py:125-230` , `scripts/train_ppo_2action2.py:114~`). 아래 표의 가중치는 두 스크립트의 `config` 실제 사용값이다.

항목	수식	가중치(최종 사용값)	적용 조건	file:line
velocity (속도 보상)	<code>reward += speed * velocity_weight</code>	<code>velocity_reward_weight = 0.003</code>	on-track (<code>off_track=False</code>) 이고 <code>speed > 0</code> 일 때만	wrapper :196-199 , config :55
survival (생존 보상)	<code>reward += survival_reward</code>	<code>survival_reward = 0.0</code> (비활성)	(현재 0이라 무효과; 정지 버티기 꼼수 차단 목적으로 제거)	config :56
track_penalty (이탈 패널티)	<code>reward -= track_penalty</code>	<code>track_penalty = 1.0</code>	off-track 일 때 (이때 velocity 보상은 미지급)	wrapper :188-192 , config :57
steering_smooth (조향 급변)	<code>reward -= steer - last_steer * steering_smooth_weight</code>	<code>steering_smooth_weight = 0.001</code>	매 스텝	wrapper :202-205 , config :58

항목	수식	가중치(최종 사용값)	적용 조건	file:line
accel_turn (코너 가속)	<code>reward -= weight * gas * steer (gas = max(0, action[1]))</code>	장애물: 최종 0.2 (config 기본 0.5; CLI로 하향) / 베이스: 항 자체가 미구현	<code>weight > 0</code> 이고 조향 중 가속할 때만(직진 가속은 비용 0)	wrapper :213-217, config :59, CLI :268-269

속도(speed) 계산 주의점: CarRacing-v3는 `info` 에 `speed` 를 제공하지 않아(항상 0) 속도 보상이 죽는다. 따라서 차량 물리에서 직접 계산한다 — `vx, vy = car.hull.linearVelocity; speed = sqrt(vx2 + vy2)` (`scripts/train_ppo_2action_obstacles.py:166-173`).

off-track 판정: 관측 픽셀의 차량 영역(`obs[84:94, 42:54]`)에서 초록 채널 평균 > 150 이고 빨강 채널 평균 < 100 이면 잔디 위로 간주한다 (`scripts/train_ppo_2action_obstacles.py:181-185`).

weight 튜닝 메모(코드 주석 근거): - `velocity_weight` 는 0.03이면 step당 ~0.9로 네이티브 보상을 압도해 0.003으로 낮춤 (실속도 ≈ 20~60) (:55). - `accel_turn_weight` (코너 가속 억제)는 장애물 스크립트에만 구현돼 있고 베이스(train2) `RewardShapingWrapper`에는 **항 자체가 없다**(인자만 받고 버림). 장애물 스크립트도 config 기본값은 0.5이나, 실험 결과 0.5는 reward만 깎고 트랙 이탈(실제 원인은 장애물 충돌)을 줄이지 못해 CLI로 0.2로 하향한 것이 최종값이다(상세는 장애물 보고서 5 진단 참조). 즉 “코너 패널티”는 이탈의 진짜 레버가 아니었다. - `steering_smooth_weight` 는 0.01이 움직임을 과도하게 방해해 0.001로 대폭 하향했다 (:58).

요약

학습 신호(shaped) = 네이티브 보상(−0.1 /프레임, +1000/N /타일, 이탈 −100 +종료) + 장애물 패널티(충돌 스텝당 −15, 비종료, 스텝당 1회) + shaping(velocity +speed*0.003 on-track, off-track −1.0, steering_smooth −0.001*Δsteer, accel_turn −weight*gas*|steer|). 평가/보고 점수는 shaping을 제거한 **clean reward**(네이티브 + 장애물 패널티)로만 측정하여 모델·환경 간 비교의 공정성을 확보했다.

관련 파일 (절대경로) - `/Users/younghoon-kang/AICarRacing/src/car_racing_obstacles.py` — 장애물 환경 및 충돌 패널티 - `/Users/younghoon-kang/AICarRacing/scripts/train_ppo_2action_obstacles.py` — `RewardShapingWrapper`(장애물, accel_turn=0.5) + config - `/Users/younghoon-kang/AICarRacing/scripts/train_ppo_2action2.py` — `RewardShapingWrapper`(베이스, accel_turn=0.0) + config - `/Users/younghoon-kang/anaconda3/envs/racing/lib/python3.11/site-packages/gymnasium/envs/box2d/car_racing.py` — 네이티브 CarRacing 보상

2. 강화학습 알고리즘 — PPO 이론

본 절은 우리가 사용한 **PPO(Proximal Policy Optimization)** 의 이론적 배경을 정리하고, 각 이론 요소가 `src/ppo_agent_2.py` 의 어느 구현에 대응하는지를 연결한다. 우리 과제의 행동공간은 연속(steering/throttle 류의 실수값)이므로, 정책은 **가우시안 연속행동정책(Gaussian continuous-action policy)** 으로 구현하였다.

2.1 Actor-Critic 구조

PPO는 정책(policy)과 가치함수(value function)를 동시에 학습하는 **Actor-Critic** 계열 알고리즘이다.

- **Actor(정책망)** 는 상태 s 를 입력받아 행동분포 $\pi(a|s)$ 를 출력한다. 우리 구현에서는 CNN으로 추출한 특징 벡터를 받아 **가우시안 분포의 평균 μ 와 로그표준편차 $\log \sigma$** 를 출력한다(`Actor.forward`, `src/ppo_agent_2.py:67`). 평균은 `tanh` 로 `[-1, 1]` 에 제약하고(`:83`), 표준편차는 고정이라 **학습 대상(learned std)** 으로 두었다(`fixed_std=False`, `:85`). 행동분포는 `torch.distributions.Normal(mean, std)` 로 구성한다(`Actor.get_action_dist`, `:96`).
- **Critic(가치망)** 은 상태가치 $v(s)$ 를 스칼라로 추정하며, Advantage 계산과 가치손실의 타깃 역할을 한다(`Critic.forward`, `src/ppo_agent_2.py:156`).
- Actor와 Critic은 CNN 특징추출기를 공유하며, 세 모듈의 파라미터를 **하나의 Adam optimizer로 통합 최적화** 한다(`src/ppo_agent_2.py:232`).

행동 샘플링 시에는 분포에서 `sample()` 로 행동을 뽑고 각 차원의 로그확률을 합산하여 $\log \pi(a|s)$ 를 얻는다(`PP0Agent.act`, `src/ppo_agent_2.py:293`). 연속행동이므로 다차원 가우시안의 차원별 로그확률·엔트로피를 합산한다(`evaluate_actions`, `:126`).

2.2 정책 경사에서 PPO로 — 신뢰영역의 동기

순수 정책 경사(policy gradient, 예: REINFORCE/A2C)는

$$\nabla J(\theta) = E[\nabla \log \pi_{\theta}(a|s) \cdot A(s,a)]$$

형태의 추정량을 따라 정책을 갱신한다. 그러나 수집한 데이터(rollout)를 여러 epoch 재사용하면 정책이 데이터를 만든 정책 π_{old} 에서 너무 멀리 이동해 **분포 이동(distribution shift)** 이 커지고, 한 번의 큰 갱신이 정책을 붕괴(collapse)시킬 수 있다.

이를 막기 위해 **TRPO** 는 갱신 전후 정책의 KL 발산을 신뢰영역(trust region)으로 제한한다. **PPO** 는 그 아이디어를 **2차 제약 대신 1차 클리핑(clipping)** 으로 근사하여, 확률비 r_t 가 신뢰영역 `[1- $\epsilon$ , 1+ $\epsilon$ ]` 를 벗어나면 목적함수의 기여를 잘라내는 방식으로 사실상 신뢰영역을 강제한다. 구현이 단순하면서도 안정적이라 본 과제에서 채택하였다.

2.3 Clipped Surrogate Objective

핵심 정책 목적함수는 다음과 같다.

$$r_t(\theta) = \pi_{\theta}(a_t|s_t) / \pi_{old}(a_t|s_t)$$

$$L^{CLIP}(\theta) = E_t[\min(r_t \cdot A_t, \text{clip}(r_t, 1-\epsilon, 1+\epsilon) \cdot A_t)]$$

여기서 A_t 는 Advantage 추정값, ϵ 는 클리핑 폭(clip_epsilon)이다. 우리는 $\epsilon = 0.15$ 를 사용하였다(기본 0.2 대비 축소하여 신뢰영역을 좁혀 KL 폭발/붕괴를 억제, `config["clip_epsilon"] = 0.15`, `scripts/train_ppo_2action2.py:34`).

`min` 과 클리핑의 의미: Advantage가 양수일 때는 r_t 가 $1+\epsilon$ 를 넘어도 이득이 더 커지지 않게 상한을 두고, 음수일 때는 r_t 가 $1-\epsilon$ 아래로 내려가도 더 내려가지 않게 하한을 둔다. 즉 신뢰영역 밖으로의 과도한 갱신에 대한 인센티브를 제거한다.

구현은 수치적으로 $r_t = \exp(\log \pi - \log \pi_{old})$ 로 계산하며, 부호가 반대인 정책손실(최소화 대상)로 변환한다(`src/ppo_agent_2.py:501`, `:505 - :507`):

```
ratio = torch.exp(log_probs - old_log_probs_batch)
policy_loss_1 = advantages_batch * ratio
policy_loss_2 = advantages_batch * torch.clamp(ratio, 1 - self.clip_epsilon, 1 +
self.clip_epsilon)
policy_loss = -torch.min(policy_loss_1, policy_loss_2).mean() # = -L^CLIP
```

2.4 Advantage 추정 — GAE

Advantage는 **GAE(Generalized Advantage Estimation)** 로 추정하여 편향-분산을 절충한다. TD 오차

$$\delta_t = r_t + \gamma \cdot V(s_{t+1}) \cdot (1 - \text{done}) - V(s_t)$$

를 정의하고, GAE는 이를 재귀적으로 누적한다.

$$A_t = \delta_t + (\gamma \cdot \lambda) \cdot (1 - \text{done}) \cdot A_{t+1}$$
$$R_t = A_t + V(s_t) \quad (\text{가치함수 타겟, 즉 return})$$

우리는 $\gamma = 0.99$, $\lambda = 0.95$ 를 사용한다(`config["gamma"]=0.99`, `config["gae_lambda"]=0.95`, `scripts/train_ppo_2action2.py:32 - :33`). 구현은 rollout을 뒤에서 앞으로 순회하며 위 재귀식을 그대로 적용한다(`RolloutBuffer.compute_returns_and_advantages`, `src/rollout_buffer.py:142`, `:146`, `:151`). 또한 미니배치 추출 직전에 Advantage를 버퍼 전체에 대해 **전역 정규화(평균 0, 분산 1)** 하여 스케일을 안정화한다(`src/rollout_buffer.py:189 - :191`).

2.5 손실 함수 — 정책 + 가치 + 엔트로피

총손실은 세 항의 가중합이다.

$$L_{total} = L_{policy} + vf_coef \cdot L_{value} - ent_coef \cdot H[\pi]$$

- **가치손실 L_{value}** : Critic 추정값과 GAE return의 **MSE(평균제곱오차)**. `value_loss = F.mse_loss(values, returns_batch)` (`src/ppo_agent_2.py:510`).

- **엔트로피 보너스 $H[\pi]$** : 정책 엔트로피를 키우는 방향으로 보상하여 조기 수렴/탐색 부족을 완화한다. 가우시안 정책의 차원별 엔트로피를 합산해 사용한다.
- **계수**: `vf_coef = 0.5` (표준값), `ent_coef = 0.01` (탐색 강박 완화) (`scripts/train_ppo_2action2.py:35 - :36`).

총손실 조립은 `src/ppo_agent_2.py:516` 에 있다.

```
entropy_loss = -torch.mean(entropy)
loss = policy_loss + self.ent_coef * entropy_loss + self.vf_coef * value_loss
```

부호 주의: FP32 경로(`learn`)는 `entropy_loss = -mean(entropy)` 로 정의한 뒤 `+ ent_coef * entropy_loss` 를 더하고(`:513` , `:516`), 혼합정밀 경로(`learn_mixed_precision`)는 `entropy_loss = mean(entropy)` 로 두고 `- ent_coef * entropy_loss` 를 뺀다(`:395` , `:398`). 둘 다 **엔트로피를 최대화(보너스)** 하는 동일한 효과로, 요청한 `L = policy + vf_coef * value - ent_coef * entropy` 식과 일치한다.

학습 안정화를 위해 갱신마다 전체 파라미터에 대한 **gradient clipping** 을 적용한다(`max_grad_norm = 0.5` , `src/ppo_agent_2.py:524`).

2.6 KL 신뢰영역과 early-stop — per-minibatch 강제

클리핑만으로는 큰 버퍼에서 여러 epoch를 돌 때 정책이 신뢰영역을 누적적으로 벗어날 수 있다. PPO 표준 구현은 보통 **approx_kl** 을 모니터링해 **target_kl** 을 넘으면 학습을 조기 종료한다. 우리는 안전성을 위해 이 검사를 **epoch 단위가 아니라 per-minibatch 단위** 로 수행한다(`src/ppo_agent_2.py:554`).

```
if self.target_kl is not None and approx_kl > self.target_kl * 1.5:
    print(f"Early stop: ... minibatch KL {approx_kl:.4f} > {self.target_kl*1.5:.4f}")
    continue_training = False
    break
```

- **임계값**: `approx_kl > target_kl * 1.5` , 즉 `0.03 * 1.5 = 0.045` 를 초과하면 즉시 중단한다(`target_kl = 0.03` , `scripts/train_ppo_2action2.py:38`).
- **왜 per-minibatch가 더 안전한가**: 우리 버퍼는 32,768 샘플, 미니배치 2,048 → epoch당 약 **16번의 갱신** 이 일어난다. epoch 단위로만 KL을 검사하면 한 epoch 동안 16번 갱신이 모두 적용된 **뒤에야** KL이 측정되어, 그 사이 정책이 신뢰영역을 한참 지나쳐 KL 스파이크/collapse가 발생할 수 있다. per-minibatch 검사는 **매 갱신 직후** KL을 보고 임계 초과 시 그 즉시 멈추므로(현 minibatch와 epoch 루프를 모두 break, `:556 - :560`), 신뢰영역 위반을 갱신 1회 수준으로 제한한다. 이는 본 파일 모듈 docstring에 명시된 2-action 라인 전용 안정화 수정이다(`src/ppo_agent_2.py:4 - :6`). 동일한 per-minibatch 조기 종료가 혼합정밀 경로에도 적용된다(`learn_mixed_precision` , `:446 - :452`).

approx_kl은 분산이 낮은 추정량 $E[(r-1) - \log r]$ (혼합정밀, :430) 또는 $0.5 \cdot E[(\log \pi - \log \pi_{\text{old}})^2]$ (FP32, :538)로 계산한다. 함께 clip fraction($|r-1| > \epsilon$ 인 샘플 비율)도 로깅하여 클리핑 작동 정도를 모니터링한다(:540).

2.7 학습 파이프라인 하이퍼파라미터 요약

항목	값	출처
병렬 환경 수	64 async envs	scripts/train_ppo_2action2.py:22
RolloutBuffer 크기	32,768 (= 64 envs × 512 steps)	:29
미니배치 크기	2,048	:30
PPO epochs	6	:31
할인율 γ	0.99	:32
GAE λ	0.95	:33
클리핑 ϵ (clip_epsilon)	0.15	:34
가치 계수 vf_coef	0.5	:35
엔트로피 계수 ent_coef	0.01	:36
max_grad_norm	0.5	:37
target_kl (per-minibatch, ×1.5 강제)	0.03	:38
초기 행동 std	0.5 (학습 대상)	:42, :44
학습률 스케줄	cosine 1e-4 → 1e-5 (warmup 후 코사인 감쇠)	:28, :46
혼합정밀(mixed precision)	True (CUDA)	:58
정책 종류	가우시안 연속행동정책 (learned std)	src/ppo_agent_2.py:32, :96

학습 루프는 매 rollout마다 (1) 64개 비동기 환경에서 32,768 step을 수집하고, (2) GAE로 return/advantage를 계산한 뒤(compute_returns_and_advantages), (3) 2,048 미니배치로 최대 6 epoch 동안 PPO 갱신을 수행하되 per-minibatch KL early-stop으로 안전하게 종료하고, (4) **cosine learning-rate 스케줄**(초기 1e-4 → 하한 1e-5)을 갱신한다(update_learning_rate, src/ppo_agent_2.py:303; 학습 루프 scripts/train_ppo_2action2.py:278 - :374). CUDA에서는 learn_mixed_precision이 autocast / GradScaler 기반 혼합정밀로 동작하여 메모리/속도를 개선한다(src/ppo_agent_2.py:343, :375, :405).

Part I — 베이스 복구 · 스케일업 · 장애물 round-1

1. 개요 / 목표

본 프로젝트(AICarRacing)는 Gymnasium `CarRacing-v3` 환경을 대상으로 한 2-action PPO(Proximal Policy Optimization) 에이전트를 개발·복구·확장한 작업이다. 진행 흐름은 다음 네 단계로 요약된다.

1. **원래 목표** — 평가(evaluation) 시 최고 성능 모델의 주행 영상을 녹화하는 스크립트 (`scripts/record_video.py`)를 구축한다.
2. **붕괴 복구** — 다운로드한 기존 2-action 학습 라인(`models/ppo_2action2`)이 PPO 붕괴(collapse)로 망가져 있음을 진단하고, 3개의 독립적인 버그를 수정하여 정상 학습 곡선을 복원한다.
3. **성능 확장** — 복구된 모델을 6M → 20M 스텝으로 스케일업하여 기존 3-action 베이스라인을 능가하는 모델을 확보한다.
4. **태스크 확장 + 개선** — 무작위 정적 장애물 회피 태스크(`CarRacingObstacles-v0`)를 신설해 파인튜닝하고(완료), 마지막으로 코너에서의 가속 억제(corner-deceleration) 보상 향을 구현한다(구현 완료·학습 미수행).

달성 요약: 붕괴된 모델(임베디드 shaped mean_reward **-17.06**)을 복구하여, 최종 베이스 모델 (`ppo_2action4/best_model.pth`, global_step **9.83M**, shaped **837.99**)이 clean 평가에서 평균 **667.49**를 기록했다. 이 수치는 3-action 저장 모델의 임베디드 shaped 값(`BestSavedAgents/evaluated641.pth` **674.55**, `BestSavedAgents/Evaluated679.pth` **637.95** — 저장 시점의 임베디드 mean이며 clean 평가가 아님)과 동급 이상이다. 추가로 장애물 회피 에이전트(clean obstacle 평가 평균 **330.99**)를 학습시켜 동일 시드 기준 before/after에서 명확한 개선(seed42: -68 → +323, seed43: 237 → 707)을 확인했다. (4단계의 코너 감속 보상은 구현·검증만 완료되었고 round-2 학습은 미수행이므로, 위 모든 결과 수치는 **accel-turn 패널티가 비활성(weight=0.0)** 상태에서 산출된 라운드-1 결과다.)

2. 시스템 구성

2.1 환경 (Environment)

- **기본 환경:** Gymnasium `CarRacing-v3`, 연속 제어(`continuous=True`), `domain_randomize=False`. (이하 학습/파인튜닝의 출발점이 되는 “주행 베이스라인 모델”과 구분하기 위해, 환경 자체는 “기본 환경”으로 표기한다.)
- **에이전트 관측(observation):** `reset()` / `step()` 이 `self._render("state_pixels")` 로 생성하는 **96×96** 프레임 grayscale 변환 후 4장 스택한 것 (`frame_stack=4`). 즉 정책이 실제로 보는 입력은 **96×96 grayscale ×4**이다.
- **rgb_array 렌더 해상도:** 영상 녹화/사람용 뷰의 `env.render()` 출력은 **400×600×3**, `render_fps=50`이다 (본 보고서 작성 시 `racing` 환경에서 `env.render().shape` 로 경험적으로 확인). 이는 에이전트 관측(96×96 `state_pixels`)과는 별개의 디스플레이용 프레임이며, 정책 입력에는 사용되지 않는다.

- 에피소드 길이: `max_episode_steps=1000` (CarRacing-v3 내장 TimeLimit와 동일).

2.2 2-action vs 3-action 과 ActionWrapper

좌표계	차원	성분	위치 / 변환
정책 출력 (2-action)	2D	<code>[steering, throttle]</code>	<code>Actor.fc_mean</code> 의 출력. 본 보고서의 모든 학습/평가 라인이 이것(<code>action_dim=2</code>)
ActionWrapper 변환 후 (네이티브 3D)	3D	<code>[steering, gas, brake]</code>	ActionWrapper가 매핑: <code>throttle>0 → gas</code> , <code>throttle<0 → brake</code>
RewardShapingWrapper 내부에서 보는 action	3D	<code>[steering, gas, brake]</code>	셰이핑 래퍼는 ActionWrapper 안쪽에 위치하므로 이미 3D를 받는다. 따라서 래퍼 코드의 <code>action[0]=steer</code> , <code>action[1]=gas</code> (6.3 참조)
3-action (비교군)	3D	<code>[steering, gas, brake]</code>	네이티브 출력, 변환 없음

Actor의 출력 차원은 `action_dim = action_space.shape[0]`로 결정되며(2 또는 3), 본 보고서의 모든 학습/평가 라인은 2-action(`action_dim=2`)이다. 좌표계 전환 지점은 위 표 1행(정책 2D 출력) → 2행(ActionWrapper 통과 후 3D)이고, 보상 셰이핑 래퍼는 그 3D를 받는다(6.3에서 역참조).

2.3 에이전트 아키텍처 (CNN / Actor / Critic)

입력은 4채널 96×96 grayscale. CNN 특징 추출기(`src/cnn_model.py`)의 정확한 구조는 다음과 같다.

```
Input (4, 96, 96), 정규화: obs / 255.0
→ Conv2d( 4→16, k=8, s=4) → ReLU → Dropout2d(0.1)
→ Conv2d(16→32, k=4, s=2) → ReLU → Dropout2d(0.1)
→ Conv2d(32→64, k=3, s=1) → ReLU → Dropout2d(0.1)
→ Flatten
→ Linear(n_flatten → features_dim) → Dropout(0.2) → ReLU
가중치 초기화: Conv/Linear 모두 Kaiming Normal (fan_out, ReLU)
```

- **Actor** (Gaussian): `fc1: Linear(features_dim→256) → fc2: Linear(256→256) → fc_mean: Linear(256→action_dim)`. `fc_mean`은 orthogonal 초기화(gain 0.01, bias 0.0). `hidden_dim=256`. (즉 `fc1`의 입력 차원은 하드코딩 256이 아니라 설정값 `features_dim`이며, 본 학습에서 `features_dim=256`이라 결과적으로 256→256이 된다.)
- **Critic**: `fc1: Linear(features_dim→256) → fc2: Linear(256→256) → fc_value: Linear(256→1)`. `hidden_dim=256`.

- `features_dim`의 출처가 두 가지로 갈리므로 명확히 구분한다: `CNNFeatureExtractor` 생성자의 기본값은 256이고 실제 학습에서도 256을 사용한다. 한편 학습 스크립트가 `config` 디렉터리에서 키를 읽을 때의 폴백(키 부재 시 기본값)은 64다(`ppo_agent_2.py` / `ppo_agent.py` 에서 `config.get("features_dim", 64)`). 본 학습 `config`에는 `features_dim=256` 이 명시되어 있어 폴백 64는 실제로 사용되지 않는다.

2.4 벡터화 PPO 파이프라인

flowchart LR

```

    subgraph VEC["AsyncVectorEnv (64 envs)"]
        E["CarRacing(-v3 / Obstacles-v0)"]
        RS["RewardShapingWrapper<br/>(velocity / track / steering / accel-turn)<br/>※ env_wrappers가 아닌 각 학습 스크립트에 인라인 정의"]
        AW["ActionWrapper<br/>(2D → 3D)"]
        GS["GrayScaleObservation"]
        TL["TimeLimit (1000)"]
        FS["FrameStack (4)"]
        E --> RS --> AW --> GS --> TL --> FS
    end
    FS -->|"4×96×96 obs"| AG
    subgraph AG["PPOAgent (ppo_agent_2.py)"]
        CNN["CNN FeatureExtractor (256)"] --> ACT["Actor (Gaussian)"]
        CNN --> CRI["Critic"]
    end
    AG -->|"actions"| VEC
    AG --> RB["RolloutBuffer (32768)"]
    RB -->|"GAE, minibatch 2048"| LEARN["learn / learn_mixed_precision<br/>per-minibatch KL early-stop"]
    LEARN --> AG
    LEARN --> TB["TensorBoard scalars"]

```

- **래퍼 순서(내부→외부):** `RewardShapingWrapper` → `ActionWrapper` → `GrayScaleObservation` → `TimeLimit(1000)` → `FrameStack(4)`. (즉 보상 셰이핑 래퍼는 `ActionWrapper` **안쪽**에 위치하므로, 그 내부에서 받는 `action`은 3D [steer, gas, brake] 이다.)
- **`RewardShapingWrapper`의 위치(중요):** 이 래퍼는 `src/env_wrappers.py`에 존재하지 않으며(`grep 0`건 확인), 각 학습 스크립트 안에 **인라인** 정의되어 있다 — 베이스용은 `scripts/train_ppo_2action2.py` (line 114~), 장애물용은 `scripts/train_ppo_2action_obstacles.py` (line 121~). **두 사본이 별도로 존재하며**, 베이스 사본은 `accel-turn` 가중치가 0.0, 장애물(round-2) 사본은 0.5다. (`env_wrappers.py`가 제공하는 것은 `GrayScaleObservation` / `FrameStack` / `TimeLimit` / `ActionWrapper` 뿐이다.)
- **벡터 환경:** `AsyncVectorEnv`, 64개 비동기 환경(`async_envs=True`).
- **버퍼:** `RolloutBuffer`, 크기 32768 (= 64 envs × 512 steps), minibatch 2048.
- **혼합 정밀도:** `mixed_precision=True` → `learn_mixed_precision()` 사용.
- **로깅:** `TensorBoard` 스칼라(보상/패널티/주행 지표/손실).

2.5 로컬 / 원격 셋업

머신	역할	환경
원격 GPU	학습	A100, conda env <code>teamB_env</code> , <code>/home/data/teamB/AICarRacing</code> , device <code>cuda</code>
로컬 (macOS)	평가 · 영상 녹화	conda env <code>racing</code> : python 3.11, gymnasium 1.3.0, box2d-py, pygame, torch 2.11.0 , imageio + ffmpeg

모델은 원격에서 학습 후 로컬로 다운로드하여 평가/녹화한다. (torch 버전은 `racing` 환경에서 `pip show torch` 로 확인한 실제 설치 값 **2.11.0**이다.)

3. 문제 진단 및 해결 (기술적 핵심)

3.1 베이스 모델 붕괴: 3개의 독립 버그

다운로드한 `models/ppo_2action2/best_model.pth` 는 임베디드 shaped `mean_reward = -17.06` (global_step 4,915,200)였다. TensorBoard 분석 결과:

- `approx_kl` 이 최대 **43.9**까지 폭발 (정상 범위 ~0.01-0.05) → 전형적인 PPO 신뢰 영역(trust-region) 붕괴.
- `value_loss` 가 **753**까지 스파이크.
- Learning Rate가 학습 내내 최솟값 **1e-5**에 고정.

이 단일 증상 뒤에 **3개의 독립적 버그**가 있었다.

(a) KL early-stop이 epoch 단위로만 동작

- **근본 원인:** 원본 `ppo_agent.py` 는 KL을 **epoch당 1회만** 검사한다. 즉 한 epoch 내 ~16개 minibatch 업데이트를 모두 마친 뒤 minibatch 루프 바깥에서 `epoch_mean_kl` 을 계산하여 break한다. 큰 버퍼에서는 검사 시점 이전에 정책이 `target_kl` 을 넘어 폭주한다.
 - 메서드별 KL 식·동작(라인은 리팩터링에 취약하므로 메서드명+조건식을 주 참조로, 라인은 보조로 표기):
 - `ppo_agent.py::learn()` — per-epoch `epoch_mean_kl` 검사 후 break (조건식은 `learn` 의 `approx_kl = 0.5*mean((log_probs - old)^2)` 기반; 대략 lines 533-535).
 - `ppo_agent.py::learn_mixed_precision()` — 동일 per-epoch 검사 (KL 식 `(exp(log_ratio)-1) - log_ratio` 의 mean; 대략 lines 432-434).
- **수정:** 2-action 전용 fork `src/ppo_agent_2.py` 를 생성하고, KL 검사를 **minibatch 루프 내부**로 이동. 한 minibatch의 `approx_kl` 이 `target_kl * 1.5` 를 초과하는 즉시 break.

```

if self.target_kl is not None and approx_kl > self.target_kl * 1.5:
    print(f"Early stop: epoch {epoch+1} minibatch KL {approx_kl:.4f} > {self.target_kl*1.5:.4f}")
    continue_training = False
    break

```

continue_training 플래그(epoch 루프 전 True 로 초기화)가 내부·외부 루프를 모두 끊는다. ppo_agent_2.py 의 learn() 과 learn_mixed_precision() 양쪽 모두에 동일 적용된다(메서드명을 주 참조로; 라인 보조 — learn() 의 break 블록은 대략 lines 554-559, learn_mixed_precision() 은 대략 lines 446-449이며 learn_mixed_precision() 메서드 정의 자체는 line 343, learn() 은 line 464). KL 지표 정의는 메서드별로 다르다 — learn(): $\text{approx_kl} = 0.5 * \text{mean}((\log_probs - \text{old})^2)$, learn_mixed_precision(): $\text{approx_kl} = \text{mean}((\exp(\log_ratio) - 1) - \log_ratio)$. (이 메서드↔식 매핑은 v1/v2 두 파일에서 동일하다.)

(b) LR 스케줄러 오호출 → 1e-5 고정

- **근본 원인:** 원본 학습 스크립트가 update_learning_rate() 에 progress_remaining (1.0→0.0 분수)을 넘겼으나, 원본 함수는 total_timesteps (상수, 수백만)를 기대했다. 더 근본적으로 원본은 호출당 증가하는 작은 rollout 카운터(수백)를 수백만의 total_timesteps 로 나눠 progress가 항상 ~0 → LR이 사실상 고정 (min_lr=1e-5, 정상보다 10배 낮음)되었고, 마지막 스텝에서 ZeroDivisionError 까지 발생.
- **수정:** 호출 시 total_timesteps 를 올바르게 전달하고, update_learning_rate 를 env-step(current_step) 기반으로 재작성. 새 시그니처는 update_learning_rate(self, current_step, total_timesteps).

```

denom = max(total_timesteps - self.lr_warmup_steps, 1)
progress = min(max((current_step - self.lr_warmup_steps) / denom, 0.0), 1.0)
current_lr = self.initial_lr * 0.5 * (1.0 + np.cos(np.pi * progress))
current_lr = max(current_lr, self.min_lr)

```

학습 스크립트 호출부(scripts/train_ppo_2action2.py line 374): current_lr = agent.update_learning_rate(global_step, config["total_timesteps"]). 이로써 코사인 스케줄이 1e-4 → 1e-5 를 실제로 스왑한다.

(c) 죽은(dead) 속도 보상

- **근본 원인:** 세이핑이 speed = info.get("speed", 0.0) 로 속도를 읽었으나 CarRacing-v3의 info dict는 비어 있어 speed가 항상 0 → 전진 유도 속도 보상이 한 번도 발화하지 않았다.
- **수정:** 물리량에서 직접 속도 계산 (RewardShapingWrapper.step 내부 — 베이스 사본은 scripts/train_ppo_2action2.py lines 147-177).

```

car = getattr(self.env.unwrapped, "car", None)
vx, vy = car.hull.linearVelocity # car가 None이면 speed = 0.0
speed = float((vx * vx + vy * vy) ** 0.5)

```

velocity_reward_weight 를 **0.003**으로 낮춤(실제 온트랙 속도 ~20-60이므로 0.03이면 스텝당 ~0.9가 더해져 베이스 보상을 압도하고 value_loss를 재팽창시킴). 속도 보상은 **온트랙이고 speed>0일 때만** $speed * 0.003$ 으로 적용; 오프트랙 시에는 보상 없이 track_penalty=1.0 만 차감.

추가 안정화

learning_rate 3e-4→**1e-4**, clip_epsilon 0.2→**0.15**, target_kl 0.015→**0.03**(이제 per-minibatch 강제), initial_action_std 0.4→**0.5**, num_envs 128→**64**.

4. 실험 결과

4.0 평가 프로토콜 (정의)

이하 4의 모든 수치는 다음 정의를 따른다. 각 표는 본 소절을 참조한다.

- **shaped reward**: 학습 시 RewardShapingWrapper (velocity/track/steering/accel-turn 항)가 더해진 보상. 체크포인트에 “임베디드 mean_reward”로 저장되는 값이 이것이다.
- **clean reward**: 평가 시 RewardShapingWrapper 를 **제거**하고(세이핑 항을 전부 끄) 환경의 **네이티브 보상만** 측정한 값. 세이핑 제거가 끄는 것은 정확히 velocity reward / track penalty / steering-smooth penalty / accel-turn penalty의 4개 항이다.
- **공통 평가 조건**: 베이스 clean 평가 = **100 episodes, seed 42, device cpu**(재현성). 장애물 clean 평가 = **50 episodes, seed 42, --obstacles, device cpu**. 모든 결과는 accel-turn 패널티 미적용(weight=0.0) 상태의 라운드-1 결과다(round-2 accel-turn 학습은 미수행).
- **3-action 비교값(674.55 / 637.95)의 출처**: 이는 clean 평가가 아니라 해당 저장 모델의 **저장 시점 임베디드 shaped mean**이다. 따라서 2-action clean 값과 직접 동일조건 비교는 아니며 “동급 수준” 참고치로 본다.

4.1 (a) 2-action 베이스 모델 복구 및 스케일업

복구 곡선 (6M, shaped reward) — 6M 시점에도 상승 중이어서 6M 체크포인트에서 이어 20M 런으로 스케일업:

global_step	shaped reward	비고
3.7M	292	복구 초기
6.0M	414	6M 종료(상승 지속)
(run 중 피크)	448	건강한 지표·정상 종료

스케일업 곡선 (20M, shaped reward; 6M 체크포인트에서 이어 학습):

global_step	shaped reward	비고
7.2M	643	이미 3-action ~650 수준

global_step	shaped reward	비고
9.83M	837.99	최고 체크포인트로 저장 (ppo_2action4/best_model.pth)
20.0M	689	피크 후 소폭 퇴보

→ shaped 보상은 ~9.8M에서 피크 후 20M까지 689로 소폭 퇴보. **교훈: 20M은 과도, ~10-12M이 sweet spot.**

Clean 평가 (셰이핑 제거 — 4.0 참조; 100 episodes, seed 42):

모델	mean ± std	median	Q1	Q3	min	max
best_model (9.8M)	667.49 ± 195.69	745.73	541.04	823.21	152.15	882.33
latest_model (20M)	555.83 ± 202.25	578.07	366.51	730.63	102.85	866.33

best_model이 **모든 지표에서 우세** → 최종 베이스 모델로 채택. clean mean 667 / median 745는 3-action 저장 모델의 임베디드 shaped 값(4.0 출처 참조)과 동급 이상.

남은 약점: bimodal 분포 (대부분 660-882이나 실패 꼬리 존재, min 152.15). 영상 진단상 실패 모드 = 급커브에서 트랙 이탈 후 잔디에서 회복 실패. (참고: videos_2action_final 의 5개 에피소드 seed42-46 보상 = 564 / 402 / 250 / 406 / 838.)



그림. 베이스 2-action 최종 모델(9.8M) 주행 — seed46, 보상 838 (clean 평균 667의 상단)

(b) 3-action 비교

아래 3-action 두 수치는 clean 평가가 아니라 **저장 시점 임베디드 shaped mean**이다(4.0). 파일 케이스는 실제 디스크 상태 그대로 표기한다(evaluated641.pth 는 소문자 e, Evaluated679.pth 는 대문자 E).

모델	지표	값
2-action best (9.8M) models/ppo_2action4/best_model.pth	clean mean / median (100 ep, seed 42)	667.49 / 745.73
3-action BestSavedAgents/evaluated641.pth	임베디드 shaped (저장 시점)	674.55
3-action BestSavedAgents/Evaluated679.pth	임베디드 shaped (저장 시점)	637.95

→ 2-action 라인이 (조건 차이를 감안하더라도) 3-action 베이스라인을 매칭하거나 능가.

4.2 장애물 회피 (round 1)

참고: 본 절의 결과는 모두 **accel-turn 패널티 미적용(weight=0.0)** 상태에서 산출되었다. accel-turn(weight=0.5)은 6의 round-2 계획이며 아직 학습되지 않았다.

학습 곡선 (10M, shaped reward):

global_step	shaped reward	비고
65k	52	급락 — 사전학습된 주행 정책이 처음 보는 장애물에 충돌
2.4M	360	회복
8.3M	431	후반

per-minibatch KL early-stop이 epoch 3에서 간헐적으로 발화(설계대로 동작). 에피소드 보상 범위 -114 ~ 1028.

체크포인트 (임베디드 shaped): best **474.84** @ global_step 4,915,200(~4.9M), latest **402.08** @ 9,830,400(~9.8M). → latest가 자기 best보다 낮음(후반 퇴보).

Clean 장애물 평가 (세이핑 제거 — 4.0; 50 episodes, seed 42, `--obstacles`):

지표	mean ± std	median	Q1	Q3	min	max
값	330.99 ± 206.71	321.82	178.79	474.76	-98.94	809.75

Before / After (동일 시드, 장애물 환경):

seed	before	after	비고
42	-68	+323	before: 장애물 정면 충돌 후 step 300에서 ~1.94로

seed	before	after	비고
			정체 / after: 깔끔히 통과, 같은 step에서 ~311
43	237	707	after 영상: 스키드 마크와 함께 장애물 우회 조향

(videos_obstacles_after 5개 에피소드 seed42-46 = 323 / 707 / 334 / 301 / 724, 평균 ~478로 체크포인트 ~475와 정합. videos_obstacles_before 는 seed42-43 2개만 존재.)

 best_model ep 1/2 seed 42 step 240 reward 22.94 46289752701	 best_model ep 1/5 seed 42 step 240 reward 215.42 96113074255
Before (장애물 학습 전): seed42 step240 — 흰 장애물로 정면 돌진, 누적 -68	After (장애물 학습 후): seed42 step240 — 도로 위 정상 주행·회피, 누적 +323

5. 장애물 환경 설계 (CarRacingObstacles-v0)

파일: src/car_racing_obstacles.py | 부모 클래스: CarRacing (class CarRacingObstacles(CarRacing))

5.1 등록 및 기본값

gymnasium.register() 로 환경 ID를 등록하며, 중복 등록 가드(if "CarRacingObstacles-v0" not in gym.registry)를 파일 말미에 배치한다.

항목	값
id	"CarRacingObstacles-v0"
entry_point	"src.car_racing_obstacles:CarRacingObstacles"
max_episode_steps	1000
reward_threshold	900

생성자 기본값:

파라미터	기본값	설명
<code>n_obstacles</code>	<code>10</code>	트랙에 배치할 장애물 수
<code>obstacle_penalty</code>	<code>15.0</code>	충돌 스텝당 차감 보상
<code>obstacle_size_min/max</code>	<code>0.25 / 0.6</code>	장애물 크기 범위 (<code>TRACK_WIDTH</code> 분수)
<code>start_clear_tiles</code>	<code>30</code>	출발선 주변 장애물 금지 구간
<code>min_tile_gap</code>	<code>12</code>	장애물 간 최소 타일 간격

Note: 원본 보고서의 `obstacle_size=0.4` 고정값을 `[obstacle_size_min, obstacle_size_max]` 범위 샘플링으로 확장하였다. 이는 에피소드마다 장애물 크기가 달라져 정책의 일반화를 유도하기 위함이다.

```
class CarRacingObstacles(CarRacing):
    def __init__(self, *args, n_obstacles=10, obstacle_penalty=15.0,
                  obstacle_size_min=0.25, obstacle_size_max=0.6,
                  start_clear_tiles=30, min_tile_gap=12, **kwargs):
        super().__init__(*args, **kwargs)
        self.n_obstacles = n_obstacles
        self.obstacle_penalty = obstacle_penalty
        self.obstacle_size_min = obstacle_size_min
        self.obstacle_size_max = obstacle_size_max
        self.start_clear_tiles = start_clear_tiles
        self.min_tile_gap = min_tile_gap
        self.obstacle_bodies = []
        self.obstacle_hits_pending = 0
```

5.2 픽셀 가시성 (관측에 그려 넣기)

핵심 설계: 장애물을 물리 세계에만 두지 않고 96×96 픽셀 관측에 직접 그려 넣는다. 회전된 quad를 `road_poly`에 `OBSTACLE_COLOR = (255, 255, 255)` (흰색)로 추가한다. grayscale 기준 255 vs 도로 ~102, 잔디 ~162와 **고대비**를 형성하여 픽셀 입력 에이전트가 인지 가능하다.

구석 좌표 ($\pm\text{half}$, $\pm\text{half}$) 를

$$c, s = \cos\beta, \sin\beta$$

로 회전:

$$p_{x'} = dx \cdot c - dy \cdot s, \quad p_{y'} = dx \cdot s + dy \cdot c$$

```
OBSTACLE_COLOR = (255, 255, 255) # grayscale 255 - 도로 ~102, 잔디 ~162 대비
```

```
# _spawn_obstacles() 내부 - 장애물 1개당 실행
```

```
c, s = math.cos(beta), math.sin(beta)
```

```
quad = [
```

```
    (px + dx*c - dy*s, py + dx*s + dy*c)
```

```
    for dx, dy in ((-half, -half), (half, -half), (half, half), (-half, half))
```

```
]
```

```
self.road_poly.append((quad, OBSTACLE_COLOR))
```

5.3 배치 및 재현성 (_spawn_obstacles)

- **타일 후보:** `range(start_clear_tiles, n_tiles - start_clear_tiles)` — 루프 트랙이므로 양 끝을 모두 **비움**. `n_tiles <= 2*start_clear_tiles + 1` 이면 early-return.
- 후보를 `self.np_random.shuffle()` 로 셔플(시드별 재현 가능) 후, 이미 선택된 것들과 `>= min_tile_gap` 떨어지도록 **greedy** 선택, 최대 `n_obstacles` 개. 선택 인덱스는 `self.obstacle_tile_indices` 에 저장.
- **반쪽 크기:** `half = np_random.uniform(size_min, size_max) * TRACK_WIDTH / 2.0`
- **주행 가능 간격 보장:** `max_offset = 0.8 * TRACK_WIDTH - half`, `offset = np_random.uniform(-max_offset, max_offset)` — 장애물 바깥 가장자리를 도로 반폭의 ~80% 안쪽에 두어 **항상 한쪽에 통로가 남게 함**.
- **위치:** `(_, beta, x, y) = track[idx]` 에서
$$p_x = x + \text{offset} \cdot \cos\beta, \quad p_y = y + \text{offset} \cdot \sin\beta$$
— $(\cos\beta, \sin\beta)$ 가 도로 **횡단축**.
- **물리 body:** `CreateStaticBody(position=(px,py), angle=beta, fixtures=fixtureDef(shape=polygonShape(box=(half,half))))`, `body.userData = _ObstacleMarker()`

```
def _spawn_obstacles(self):
    self.obstacle_bodies = []
    n_tiles = len(self.track)
    if n_tiles <= 2 * self.start_clear_tiles + 1:
        return # 트랙이 너무 짧으면 스킵

    candidates = list(range(self.start_clear_tiles, n_tiles - self.start_clear_tiles))
    self.np_random.shuffle(candidates) # 시드별 재현 가능 셔플

    chosen = []
    for idx in candidates:
        if len(chosen) >= self.n_obstacles:
            break
        if all(abs(idx - c) >= self.min_tile_gap for c in chosen):
            chosen.append(idx) # greedy gap 필터

    self.obstacle_tile_indices = list(chosen)
```

```

for idx in chosen:
    _, beta, x, y = self.track[idx]
    size_frac = self.np_random.uniform(self.obstacle_size_min, self.obstacle_size_max)
    half = size_frac * TRACK_WIDTH / 2.0
    max_offset = max(0.0, 0.8 * TRACK_WIDTH - half)
    offset = self.np_random.uniform(-max_offset, max_offset)
    px = x + offset * math.cos(beta)
    py = y + offset * math.sin(beta)

    body = self.world.CreateStaticBody(
        position=(px, py), angle=beta,
        fixtures=fixtureDef(shape=polygonShape(box=(half, half))),
    )
    body.userData = _ObstacleMarker()
    self.obstacle_bodies.append(body)
    # road_poly 추가 → 픽셀 관측에 렌더링 (5.2)
    c, s = math.cos(beta), math.sin(beta)
    quad = [(px + dx*c - dy*s, py + dx*s + dy*c)
            for dx, dy in ((-half, -half), (half, -half), (half, half), (-half, half))]
    self.road_poly.append((quad, OBSTACLE_COLOR))

```

5.4 충돌 검출 및 패널티

`ObstacleFrictionDetector(FrictionDetector)` 가 `BeginContact` 를 오버라이드한다.

메서드	동작
<code>BeginContact</code>	장애물 접촉이면 <code>env.obstacle_hits_pending += 1</code> 후 <code>return</code> (부모 스킵), 아니면 <code>super().BeginContact()</code>
<code>EndContact</code>	장애물 접촉이면 early-return, 아니면 <code>super().EndContact()</code>
<code>_is_obstacle_contact</code>	<code>userData.is_obstacle</code> 확인; 예외 발생 시 <code>True</code> 반환 (파괴 중 contact가 시뮬레이터를 크래시시키지 않도록 belt-and-braces)

detector는 `reset()` 에서 `contactListener` 와 `contactListener_bug_workaround` 양쪽에 설치한다.

step 패널티: `hits = obstacle_hits_pending` (읽고 0으로 리셋). `action is not None and hits > 0` 이면 `step_reward -= obstacle_penalty(15.0)`. hit 수와 무관하게 스텝당 1회만 차감 — 한 번의 충돌이 hull+wheel 접촉을 동시에 시작할 수 있으므로. `info["obstacle_hit"] = True`, 항상 `info["obstacle_hits"] = hits` 기록. 에피소드는 종료되지 않음 (penalty-only; 차는 물리적으로 튕기며 감속).

```

class ObstacleFrictionDetector(FrictionDetector):
    def BeginContact(self, contact):
        if self._is_obstacle_contact(contact):
            self.env.obstacle_hits_pending += 1
            return # 타일 lap 카운트 스킵
        super().BeginContact(contact)

    def EndContact(self, contact):
        if self._is_obstacle_contact(contact):
            return
        super().EndContact(contact)

    @staticmethod
    def _is_obstacle_contact(contact) -> bool:
        try:
            for ud in (contact.fixtureA.body.userData,
                       contact.fixtureB.body.userData):
                if ud is not None and getattr(ud, "is_obstacle", False):
                    return True
            except Exception:
                return True # 파괴 중 contact 안전 처리
            return False

# step() 내 패널티 적용
def step(self, action):
    obs, step_reward, terminated, truncated, info = super().step(action)
    hits = self.obstacle_hits_pending
    self.obstacle_hits_pending = 0
    if action is not None and hits > 0: # 스텝당 1회만 차감
        step_reward -= self.obstacle_penalty
        info["obstacle_hit"] = True
    info["obstacle_hits"] = hits
    return obs, step_reward, terminated, truncated, info

```

6. 코너 감속 개선

코너 감속(accel-turn) 패널티는 Part I 작성 시점엔 구현만 완료·미학습이었다. 이후 실제 학습·진단을 Part II 5절에서 수행했고, 결론은 “코너 패널티는 비(非)레버”(0.5는 reward만 깎고 이탈은 충돌이 원인)였다. 상세는 Part II 5절 참조.

9. 부록

9.1 최종 안정화 하이퍼파라미터

주의: `acceleration_while_turning_penalty_weight` 는 베이스/라운드-1 런에서는 0.0(비활성)이었고, 0.5는 round-2 장애물 config에서만 설정된 값이며 아직 학습에 사용되지 않았다. 4의 결과(837.99 / 667.49 / 330.99 등)는 모두 이 가중치가 0.0인 상태에서 산출되었다. (검증: 베이스 사본 `train_ppo_2action2.py` 에서 0.0, 장애물 round-2 사본 `train_ppo_2action_obstacles.py` line 57에서 0.5.)

카테고리	파라미터	값
PPO Core	<code>learning_rate</code>	1e-4 (3e-4 → 1e-4)
	<code>min_learning_rate</code>	1e-5
	<code>clip_epsilon</code>	0.15 (0.2 → 0.15)
	<code>target_kl</code>	0.03 (0.015 → 0.03, per-minibatch)
	<code>gamma</code>	0.99
	<code>gae_lambda</code>	0.95
	<code>ppo_epochs</code>	6 (10 → 6)
	<code>vf_coef</code>	0.5 (0.75 → 0.5)
	<code>ent_coef</code>	0.01 (0.02 → 0.01)
	<code>max_grad_norm</code>	0.5
	<code>buffer_size</code>	32768 (64 × 512)
	<code>batch_size</code>	2048
	<code>lr_warmup_steps</code>	0
Agent	<code>features_dim</code>	256 (생성자 기본=256, config 폴백=64)
	<code>initial_action_std</code>	0.5 (0.4 → 0.5)
	<code>fixed_std</code>	False
	<code>weight_decay</code>	1e-6
Env	<code>num_envs</code>	64 (128 → 64)
	<code>frame_stack</code>	4
	<code>max_episode_steps</code>	1000
	<code>seed</code>	42
Reward shaping	<code>velocity_reward_weight</code>	0.003

카테고리	파라미터	값
	survival_reward	0.0 (disabled)
	track_penalty	1.0
	steering_smooth_weight	0.001 (0.01 → 0.001)
	acceleration_while_turning_penalty_weight	베이스/라운드-1: 0.0 · round-2 계획: 0.5 (NEW, 미학습)
Obstacle	n_obstacles	10
	obstacle_penalty	15.0
	obstacle_size	$0.4 \times \text{TRACK_WIDTH}$
	start_clear_tiles	30
	min_tile_gap	12
Perf	mixed_precision	True
	torch_num_threads	2 (16 → 2)
	pin_memory / async_envs	True / True

9.2 환경 버전 매트릭스 (재명시)

항목	값	출처
학습 device	A100 <code>cuda</code> , conda <code>teamB_env</code>	원격
평가/녹화 device	<code>cpu</code> (재현성), conda <code>racine</code>	로컬 macOS
python / gymnasium / torch	3.11 / 1.3.0 / 2.11.0	<code>racine</code> <code>pip show torch</code>
베이스 clean 평가	100 ep, seed 42	4.1
장애물 clean 평가	50 ep, seed 42, <code>--obstacles</code>	4.2
<code>rgb_array</code> 렌더 해상도	400×600×3 @ 50fps	<code>env.render().shape</code> 경험적 확인
에이전트 관측	96×96 grayscale ×4 (<code>state_pixels</code>)	<code>reset()</code> / <code>step()</code>

Part II — 장애물 심화 실험 (진단 · 크기 · 엔트로피 · 2 vs 3 action)

편집자 주(브리지): Part I은 프로젝트 phase-1(베이스 2-action 붕괴 복구와 장애물 round-1) 시점의 기록으로, 작성 당시 코너 감속(accel-turn) 패널티는 *구현만 완료·미학습* 상태였다. Part II는 그 이후 **실제로 수행된** 장애물 심화 실험을 다룬다 — 코너 패널티(0.5→0.2)의 실험적 기각, 장애물 크기 랜덤화, 행동 노이즈(ent_coef) 축소, 그리고 native **3-action 대조군**. 따라서 Part II는 Part I의 6(round-2 계획)을 **갱신·대체**한다.

2. 환경 설계 — CarRacingObstacles-v0

장애물 환경의 설계(등록·기본값, 픽셀 가시성, 배치·재현성, 충돌 검출·패널티, 크기 랜덤화, segfault·loop-spawn 픽스)는 **Part I 5절에 코드와 함께 통합**했다. 본 Part II는 그 환경 위에서 수행한 실험·진단을 다룬다. 장애물 크기 변형(소형 vs 대형) 실험은 아래 4절 참조.

4. 장애물 크기 실험 (소형 vs 대형)

실험	size_frac	도로 대비	과제 성격
소형(기본)	0.25-0.6	12~30%	틈으로 weaving 회피 (통과 틈 보장)
대형(설계 완료)	2.0-3.0	100~150%	도로 차단 → 잔디 우회 필수

- 검증: 소형은 장애물 전체폭 1.7-3.9 vs 도로 13.3 (전부 작음), 대형은 13.4-19.6 (전부 도로보다 큼). 시드 재현성·통과틈·도로차단 모두 확인.
- 대형의 보상 설계 긴장: 도로를 막으면 **off-road 우회만이 유일 통과법**인데, 세이핑은 off-track에 패널티(+속도보상 차단)를 줘 **유일한 통과법을 벌준다**. → 대형 실험은 `--track-penalty`를 낮춰야 가능(예 0.2). CLI로 노출함.
- 대형 실험(B)은 **학습 미수행**(설계·검증만). 본 보고서 결과는 모두 **소형(0.25-0.6)** 기준.

5. 진단 — “급커브 이탈”은 오진이었다 (계측 평가)

회원 관찰: “급커브에서 액셀을 밟는지 도로에서 크게 벗어난다.” → 코너 감속 패널티를 추가했으나, **계측으로 실제 실패 원인을 측정**한 결과 가설이 틀렸다.

5.1 코너 감속 패널티 구현

- 발견: `acceleration_while_turning_penalty_weight` 가 config에서 0이었을 뿐 아니라 **wrapper에 구현 자체가 없었다**(= 신호 부재).
- 구현: `step_penalty = weight × gas × |steering|`. 직진 가속($|steer| \approx 0$)은 무비용, 조향하며 밟을 때만 벌점. 검증: 직진 풀가스 30스텝 패널티 0.000 / 풀조향+풀가스 30스텝 15.000.

5.2 계측 결과 — 메커니즘은 작동, 그러나 결과는 무관

동일 env(소형)·동일 시드, 20ep 샘플링, 코너 가속 지표 `gas×|steer|` :

모델	clean reward	코너가속	off-track%*	충돌
obs_small (패널티 0.5)	372	0.151	29.0	2.5
round1 (패널티 없음)	455	0.263	31.6	1.9

-  코너 가속 42% 감소(0.263→0.151) — 패널티는 의도한 직접 목표를 달성.
-  그러나 off-track은 거의 불변(-2.6%p), reward는 오히려 하락(455→372). 패널티가 정책을 소심하게 만들어 reward만 깎음.
- (* off-track% 계측은 신뢰도 낮음 — “전 바퀴 도로 밖” 기준이 타일 경계/정체를 과대계상. 절대값은 버리고 추세만 참고.)

5.3 실패 원인은 충돌, 그것도 대부분 “샘플링 노이즈”

obs_small의 에피소드별 분석(시드별):

seed	reward	off%	충돌
53 (최악)	-36	0.0	6
57	127	0.0	6
52 (최고)	760	12.5	0
56	757	13.1	0

- 망한 판 = 도로 위에 잘 있는데(off 0%) 장애물 다발 충돌. 잘한 판 = 충돌 0, off-track은 오히려 높음(회피 하느라 가장자리로 weaving). → off-track은 실패가 아니라 회피 성공의 부산물.
- 결정적: 최악 seed 53을 결정론(mean action)으로 돌리니 -36 → 486, 충돌 0. → 그 충돌들은 정책 무능이 아니라 평가 시 가우시안 행동 노이즈가 가끔 장애물로 틀어버린 것.

5.4 결론: 코너 패널티는 비(非)레버 — 0.5→0.2로 reward 회복

동일 설정(소형, 50ep 샘플링)에서 패널티만 바꿔 비교:

모델	패널티	Mean	Median	Q1 / Q3	Min / Max
obs_small	0.5	365	325	221 / 482	-37 / 837
obs_small_p02	0.2	415	422	285 / 553	-65 / 842

→ 패널티를 낮추니 평균·중앙값·사분위 전부 개선(median +97). 코너 패널티는 reward만 깎았을 뿐 실패 원인(충돌)과 무관했음이 확정됨.




그림. 코너 감속 패널티는 비(非)레버 — 0.5→0.2로 낮추니 clean 보상 회복(365→415)


6. 실험 결과 종합

6.1 학습 곡선 — 이 태스크는 전반부에 정점 찍고 정체

run	패널티 / 크기	스텝	best(shaped) @ step	비고
round1 (ppo_2action_obstacles)	0 / 고정 0.4	10M	474.8 @ 4.9M	52→360→431 상승 후 정체
obs_small	0.5 / 랜덤 0.25-0.6	6M	447.4 @ 1.64M	정점 매우 이름
obs_small_p02	0.2 / 랜덤 0.25-0.6	6M	465.4 @ 3.28M	정점 후 6M엔 453로 퇴보

→ 세 run 모두 전반부(1.6M / 3.3M / 4.9M)에 정점 후 정체/퇴보. (베이스 20M도 9.8M 정점) → 순수 스텝 증가는 ROI가 낮고, 다음 실험은 4~5M이면 충분.

6.2 Clean 평가 (shaping 제외, 50ep 샘플링, seed 42)



| 모델 | Mean | Median | Min / Max | 비교 | |—|—|—|—|—| | round1 (고정 0.4) | 331 | 322 | -99 / 810 | 고정 0.4 분포 | | obs_small (0.5) | 365 | 325 | -37 / 837 | 랜덤 0.25-0.6 | | **obs_small_p02 (0.2)** | **415** | **422** | -65 / 842 | 랜덤 0.25-0.6, **현 최고** |

주의: round1은 고정 0.4로 학습/평가, obs_small·p02는 랜덤 0.25-0.6 → 크기 분포가 달라 직접 비교는 obs_small vs p02만 깨끗하다. round1 수치는 분포가 다른 참고값.

6.3 정성 (before/after, 동일 시드)

	학습 전(베이스)	학습 후(round1)
seed42	-68 (장애물에 정면 충돌, step300에 reward~1.9)	+323 (깨끗이 통과)
seed43	237	+707 (장애물 옆으로 비껴가며 스키드마크)

→ 영상: videos_obstacles_before/ (충돌), videos_obstacles_after/ · videos_obs_small/ (회피), videos_diag/ (진단용).



그림. 장애물 회피(weaving) — seed43, 보상 707: 곡선 구간에서 장애물 사이로 우회 조향

7. 마지막 실험 — 행동 노이즈 축소(ent_coef)는 비(非)레버였다

진단(5절)에 따르면 이 모델의 천장은 “학습 부족”이 아니라 **장애물 충돌**이고, 그 충돌의 상당수가 **평가 시 샘플링 노이즈**로 보였다(결정론에서 충돌이 거의 사라짐). 그렇다면 마지막 레버는 코너 패널티가 아니라 **행동 노이즈 축소**여야 한다 — ent_coef 를 낮춰 정책을 더 결정론적으로 만들면 샘플링 충돌이 줄어 실성능이 오를 것이라는 가설.

```
CUDA_VISIBLE_DEVICES=0 python -m scripts.train_ppo_2action_obstacles \
  --ent-coef 0.005 --accel-turn-weight 0.2 \
  --obstacle-size-min 0.25 --obstacle-size-max 0.6 \
  --steps 4000000 \
  --save-dir ./models/obs_p02_lowent --log-dir ./logs/obs_p02_lowent
```

7.1 결과 — 레버는 움직였으나 성능은 안 따라옴

학습 4M 완료(clean exit). 학습 지표: **losses/entropy** 1.3 → 0.91로 하락 → 노이즈 축소 레버 자체는 의도대로 작동. 그러나 50ep clean(seed 42, 동일 소형 분포):

모델	ent_coef	Mean	Median	Q1 / Q3	Min(충돌 바닥)	Max
obs_small_p02	0.01	415	422	285 / 553	-65	842
obs_p02_lowent	0.005	418	396	252 / 591	-112	811

- Mean 415 → 418: 사실상 무변화(편차 ± 231 안). Median 422 → 396으로 오히려 ↓.
- Min(충돌 바닥) -65 → -112로 악화. 최악 판(ep32 -112)은 entropy를 낮췄는데도 살아남음.

7.2 해석 — 진단의 수정: 남은 충돌은 “구조적”이지 단순 노이즈가 아니다

5.3절에서 “충돌은 대부분 샘플링 노이즈”로 보였으나(seed53 결정론 486 vs 샘플링 -36), 노이즈를 실제로 줄여 봤더니(entropy 1.3→0.91) 충돌이 줄지 않았다. Min은 오히려 악화. 즉 샘플링 노이즈는 충돌의 충분조건 중 하나였을 뿐, 제거해도 사라지지 않는 구조적 실패 케이스가 따로 남아 있다 — 정책이 특정 장애물 배치를 아직 못 푸는 것이다. (ent_coef 를 더 낮추면 탐험까지 줄어 학습 자체가 나빠질 수 있어 더 내리는 것은 권장 안 함.)

7.3 판정 — task 천장(~415) 확정

- 가설 기각. 행동 노이즈 축소는 losses/entropy 는 내렸지만 clean 성능(Mean·Median·Min)을 못 올렸다.
- 2-action 장애물 task의 clean 천장은 ~415 (Mean)으로 확정. 코너 패널티(5절)·스텝 증가(6.1절)·노이즈 축소(7절) — 시도한 세 레버 모두 이 천장을 넘지 못했다.
- 최종 채택 모델: obs_small_p02 (ent_coef 0.01, clean 415/422). lowent는 동급이나 Median·Min에서 미세 열위라 채택하지 않음.

8. 3-action 대조 실험 — 2 vs 3 action (native gas/brake)

8.1 동기과 절차

2-action(throttle 1축, ActionWrapper)이 장애물 task에서 정착한 천장(clean ~415)이 action 파라미터화 타인인지 확인하기 위해, native 3-action [steer, gas, brake] 정책으로 동일 task를 학습했다. 환경·보상·하이퍼파라미터는 2-action과 바이트 단위로 동일(n_obstacles=10, penalty=15, size 0.25-0.6, LR 1e-4 cosine, target_kl 0.03)하고 유일한 차이는 ActionWrapper 미적용(정책이 3D 네이티브 출력). 3-action 베이스 evaluated641 (무장애물 base에서 ~675)에서 fine-tune. 전용 스크립트

```
scripts/train_ppo_3action_obstacles.py · scripts/evaluate_agent_3action_obstacles.py .
```

8.2 B (ent 0.01) — 발산





그림. Entropy(=std) 곡선 — 3-action(ent0.01)은 2.0→5.3 발산, 2-action 및 3-action(ent0.003)은 안정



2-action과 동일한 `ent_coef 0.01` 로 학습하자 **entropy(=std)가 2.0→5.33으로 폭증**, reward가 피크 325(@1.1M) 후 156으로 붕괴. TB 곡선 진단(`scripts/dump_tb_scalars.py`): `ent_coef*entropy (0.053)`가 `policy_loss (0.008)`를 **6배 압도** → 옵티마이저가 보상 대신 std 키우기로 폭주. `obstacle_hits` 는 4.8→1~2로 줄어(회피는 학습) 실패 원인은 충돌이 아니라 **std 발산**. → **B는 불공정**(2D에 맞춘 ent가 3D엔 과대).

8.3 B2 (ent 0.003) — 발산 차단, 그러나 낮은 천장

`ent_coef` 를 0.003으로 낮추자(ent항/policy항 ≈ 1:1) entropy가 ~2-3.3에서 안정, 발산 소멸. 피크도 1.1M→**3.28M으로 이동**(2-action p02와 동일 시점) — 저엔트로피가 조기 발산 대신 후반까지 개선을 허용. clean 50ep(동일 분포·seed 42):

지표	2-action p02 (ent0.01)	3-action B2 (ent0.003)	3/2 비율
best shaped @step	465 @3.28M	334 @3.28M	72%
clean Mean	415	229	55%
clean Median	422	245	58%
Q1 / Q3	285 / 553	179 / 317	—
Min (충돌 바닥)	-65	-171	악화
Max	842	730	—

→ 발산을 고쳐 공정(오히려 3-action에 유리한 ent 튜닝)하게 비교해도 3-action은 2-action의 ~55%. Mean·Median 모두 큰 폭 하회, Min은 오히려 악화(-171, 깊은 충돌 판 다수).




그림. 2 vs 3 action (동일 장애물 task, clean 50ep) — 3-action은 2-action의 ~55%, 총돌 바닥 (Min)도 악화

8.4 왜 — 코드 근거 (멀티에이전트 반증 검증 완료)

동일 task·하이퍼파라미터에서 3-action만 낮은 건 **native** 독립 gas/brake action space 때문이며, 코드에 대조·반증했다:

1. gas+brake 동시 입력이 실재하는 퇴화영역 (검증 holds=true). native step은

`car.gas(action[1]) · car.brake(action[2])` 를 독립 적용(`car_racing.py:545-546`), 물리엔진에서 같은 `w.omega` 를 한 틱에 gas가 올리고 brake가 깎는 **상쇄 낭비 구간**(`car_dynamics.py:199-216`). 2-action ActionWrapper는 단일 throttle을 `gas=max(0,t)/brake=max(0,-t)` 로 분해해 이 구간을 **구조적으로 제거** (`env_wrappers.py:140-141`).

2. 무방비 brake 채널. `gas()` 는 [0,1] 클립 + 스텝당 +0.1 램프로 보호되나 `brake()` 는 클립·램프 없이 즉발 (`car_dynamics.py:146-160`). 노이즈 큰 brake가 즉시 속도를 깎아, 유일한 양의 세이핑인 `velocity=speed*0.003 (survival=0)` 을 직접 잠식.

3. 탐색 부피 ~2.9배 + 합산 엔트로피. 차원이 하나 더라 `entropy/log_prob` 이 brake축까지 합산 (`ppo_agent_2.py:126-127`) → 같은 `ent_coef` 에서 std가 발산하기 쉬움(B에서 실증).

8.5 결론과 한계

- **결론:** native 3-action은 이 장애물 task에서 **구조적으로 불리**하다. 발산을 막는 공정한(오히려 관대한) 튜닝 후에도 clean 229 vs 415 — ActionWrapper의 signed-throttle이 **퇴화영역 제거 + 탐색 축소**라는 **유용한 inductive bias**임이 확인된다. 이 프로젝트가 처음부터 2-action을 택한 근거를 사후 정당화한다.
- **한계(정직하게):** 3-action의 clean 천장을 2-action처럼 여러 lever로 **확정한 것은 아니다**(B2 단일 공정 run). 정확한 진술은 “3-action이 415를 못 넘는다”가 아니라 “**동일·관대 setting에서 3-action은 415 도달 전에 발산(ent0.01)하거나 ~229에서 정체(ent0.003)한다**”. 잔여 탐색 여지(brake축만 std 축소, gas/brake squash, 더 긴 학습)는 있으나 ROI는 낮다고 판단.

핵심 교훈 (종합)

베이스 복구(Part I)와 장애물·3-action 실험(Part II)에서 얻은 교훈을 한데 모은다.

1. PPO 붕괴는 거의 항상 신뢰영역(KL) 제어 실패 — KL은 epoch가 아니라 업데이트(minibatch) 단위로 검사하라.
2. 하나의 증상 숫자가 여러 독립 버그를 가린다 — 붕괴(reward -17) 뒤에 KL·LR·죽은 속도보상 3개가 동시에 있었다.
3. shaped reward $\neq$ clean reward — 스케일업·모델 선택은 반드시 clean 평가로 게이팅하라(shaped 838 이 clean 667).
4. 보상 셰이핑 항은 조용한 no-op일 수 있다 — 실제로 발화하는지 검증하라. 속도 보상(`info['speed'] = 0`)과 코너 패널티(미구현)가 둘 다 무발화였다.
5. 픽셀 입력 에이전트는 장애물을 관측에 직접 “그려” 넣어야 한다 — 물리 세계에만 두면 보이지 않는다.
6. Linux box2d-py는 body 파괴 중 contact 콜백에서 segfault — listener를 먼저 detach하라(macOS가 가려서 로컬에선 안 잡힘).
7. 벡터 env 로깅은 `infos[key][i]` (dict-of-arrays)로 읽어야 한다 — `infos.get(i)` (정수키)는 무음 실패.
8. 셰이핑을 추가하기 전에 실패 모드를 측정하라. “급커브 이탈”은 오진이었고, 계측(코너가속·off%·충돌/에피소드)이 진짜 원인(충돌)을 드러냈다.
9. 샘플링 vs 결정론 평가는 std가 클 때 크게 다르다 — 샘플링 노이즈가 장애물 충돌을 유발(seed53 결정론 486 vs 샘플링 -36).
10. “노이즈가 원인”은 가설로 끝내지 말고 직접 검증하라. `ent_coef` 로 노이즈를 줄여봤더니(entropy 1.3→0.91) 충돌이 안 줄었다 — 일부는 노이즈로 제거 안 되는 구조적 실패.
11. 이 태스크는 전반부에 정점 후 정체 — 코너 패널티·스텝 증가·노이즈 축소 세 레버 모두 clean ~415 천장을 못 넘음. 다음 개선은 하이퍼파라미터가 아니라 표현/아키텍처(명시적 장애물 채널, recurrent, 더 큰 CNN) 쪽이어야 한다.
12. action 파라미터화는 공짜가 아니다 — 2-action의 ActionWrapper가 유용한 inductive bias. native 3-action은 동일 조건에서 clean 229(2-action 415의 ~55%): 독립 gas/brake가 동시입력 퇴화영역·무방비 brake~2.9배 탐색부피를 만들어 std 발산/저성능을 유발.
13. 하이퍼파라미터는 차원에 따라 재튜닝하라. 2D에서 안정적이던 `ent_coef 0.01` 이 3D에선 entropy를 발산(2.0→5.33)시켰다 — `ent항/policy항` 비율로 균형을 확인하라.

구현 산출물 (커밋 안 함)

파일	상태	내용
<code>src/ppo_agent_2.py</code>	신규	2-action PPO fork — per-minibatch KL early-stop + env-step 코사인 LR
<code>src/car_racing_obstacles.py</code>	신규	<code>CarRacingObstacles-v0</code> 환경 (랜덤 크기·픽셀 렌더·충돌 패널티)

파일	상태	내용
		·segfault/loop-spawn 픽스)
src/env_wrappers.py	수정	ActionWrapper (2D [steer, throttle] → 3D [steer, gas, brake]) 추가
scripts/train_ppo_2action2.py	신규	베이스 2-action 학습 (LR/안정화 config, RewardShapingWrapper 인라인)
scripts/train_ppo_2action_obstacles.py	신규	장애물 회피 학습 fork (코너 패널 타·로깅 픽스·CLI 다수)
scripts/train_ppo_3action_obstacles.py	신규	3-action 대조군 학습 (ActionWrapper 미적용, native 3D, evaluated641서 fine-tune)
scripts/evaluate_agent_2action.py	분리(베이스)	장애물 코드 제거 → 베이스 (CarRacing-v3) 전용 clean 평가 기
scripts/evaluate_agent_2action_obstacles.py	신규	장애물 전용 평가기 (CarRacingObstacles-v0 항상 ON)
scripts/evaluate_agent_3action_obstacles.py	신규	3-action 장애물 평가기
scripts/record_video.py	신규	평가 리플레이 → mp4 녹화
scripts/dump_tb_scalars.py	신규	TensorBoard 이벤트 → 텍스트 표 + PNG 덤프 (다중 run 오버레이)
scripts/make_report_figs.py , build_combined_report.py	신규	보고서 그림·합본 생성 도구
requirements.txt , Dockerfile , build_docker.sh	신규	재현 환경 (pip / 도커 이미지)

학습 스크립트 CLI 오버라이드: `--checkpoint --steps --seed --log-dir --save-dir --n-obstacles --obstacle-size-min --obstacle-size-max --track-penalty --accel-turn-weight --ent-coef`

부록 — 재현 커맨드

학습=원격 GPU(`conda teamB_env`), 평가/녹화=로컬(`conda racing`). 스크립트는 저장소 루트에서 `python`

-m scripts.NAME 으로 실행.

```
# ===== 학습 =====
# 베이스 2-action (6M)
python -m scripts.train_ppo_2action2 --steps 6000000
# 스케일업: 6M best 체크포인트에서 total_timesteps만 20M으로 올려 재개 → ppo_2action4/best_model.pth (9.83M)

# 장애물 회피 2-action (corner penalty 0.2, 랜덤 크기)
python -m scripts.train_ppo_2action_obstacles \
    --accel-turn-weight 0.2 --obstacle-size-min 0.25 --obstacle-size-max 0.6 \
    --save-dir ./models/obs_p02 --log-dir ./logs/obs_p02

# 3-action 대조군 (ent_coef 0.003 - 3D 발산 방지)
python -m scripts.train_ppo_3action_obstacles \
    --ent-coef 0.003 --obstacle-size-min 0.25 --obstacle-size-max 0.6 \
    --save-dir ./models/obs_3action --log-dir ./logs/obs_3action

# 대형 장애물(도로보다 큼) 실험 - off-road 우회가 유일 통과법이라 track_penalty 완화 필요
python -m scripts.train_ppo_2action_obstacles \
    --obstacle-size-min 2.0 --obstacle-size-max 3.0 --track-penalty 0.2 \
    --save-dir ./models/obs_big --log-dir ./logs/obs_big

# ===== 평가 (clean) =====
python -m scripts.evaluate_agent_2action \
    --model ./models/ppo_2action4/best_model.pth --episodes 100 --seed 42 # 베이스
python -m scripts.evaluate_agent_2action_obstacles \
    --model ./models/obs_small/best_model.pth \
    --obstacle-size-min 0.25 --obstacle-size-max 0.6 --episodes 50 --seed 42 # 장애물(학습과 동일 크기 분포로!)
python -m scripts.evaluate_agent_3action_obstacles \
    --model ./models/obs_3action/best_model.pth \
    --obstacle-size-min 0.25 --obstacle-size-max 0.6 --episodes 50 --seed 42 # 3-action

# ===== 영상 녹화 (mp4) =====
python scripts/record_video.py --model ./models/ppo_2action4/best_model.pth --episodes 5
python scripts/record_video.py --model ./models/obs_small/best_model.pth \
    --obstacles --obstacle-size-min 0.25 --obstacle-size-max 0.6 --episodes 5
```

부록 A — 엔지니어링 노트 (버그 수정)

환경 구축 중 Linux box2d-py에서 해결한 핵심 버그 3종(SEGFAULT · loop-spawn · 로깅)이다. 본문 흐름과 무관한 엔지니어링 세부라 부록으로 분리한다.

A. 환경 구축 시 해결한 버그 (엔지니어링 핵심)

3.1 SEGFAULT — 본체 파괴 중 contact 콜백 재진입 (Linux box2d-py)

증상: 64개 env가 첫 에피소드를 끝내고 autoreset하는 순간 전원 segfault(`pygame_parachute`). macOS에서는 우연히 살아남아 로컬 테스트가 잡지 못했다.

원인: 차가 장애물에 닿은 채 에피소드가 끝나면, `reset()` 의 `_destroy()` 에서 `DestroyBody(장애물)` 실행 도중 Box2D가 **EndContact 콜백을 발사**한다. 이때 반쯤 파괴된 바디의 `userData` 를 Python에서 접근하면서 segfault가 발생한다.

```
reset() 호출
└─ _destroy()
    └─ world.DestroyBody(obstacle_body) ← Box2D 내부에서
        └─ EndContact(contact) 콜백 발사 ← 반쯤 파괴된 body
            └─ contact.fixtureA.body.userData 접근 → SEGFAULT
```

수정: `_destroy()` 에서 바디 파괴 **전에** `contactListener` 를 `None` 으로 분리한다. 리스너는 `CarRacing.reset()` 이 `super().reset()` 직후 재설치하므로 게임플레이에 영향이 없다.

```
def _destroy(self):
    # 바디 파괴 전 listener 분리 - 파괴 중 EndContact 재진입 segfault 방지
    self.world.contactListener = None # ← 핵심 수정
    self.world.contactListener_bug_workaround = None
    for body in self.obstacle_bodies:
        self.world.DestroyBody(body)
    self.obstacle_bodies = []
    super()._destroy()

def reset(self, *, seed=None, options=None):
    obs, info = super().reset(seed=seed, options=options) # 리스너 재설치됨
    detector = ObstacleFrictionDetector(self, self.lap_complete_percent)
    self.world.contactListener_bug_workaround = detector # 재설치
    self.world.contactListener = detector
    ...
```

3.2 차 위에 장애물 스폰 (loop-spawn)

원인: 트랙이 루프 구조이므로 끝 타일(`n_tiles - 1` 근방)이 시작선 바로 뒤에 위치한다. 앞쪽 끝(`< start_clear_tiles`)만 제외하고 뒤쪽 끝을 포함하면, 시작선 직후 타일에 장애물이 스폰되어 차 위에 겹친다.

타일 인덱스: 0 ————— `n_tiles-1`
[시작선] [시작선 바로 뒤]
← 앞쪽 끝 → ← 뒤쪽 끝 →
(루프이므로 이 두 구간이 물리적으로 인접)

수정: 배치 후보를 `range(start_clear_tiles, n_tiles - start_clear_tiles)` 로 양끝 모두 제외한다. 트랙이 너무 짧아 유효 구간이 없으면(`n_tiles <= 2 * start_clear_tiles + 1`) early-return한다.

```
def _spawn_obstacles(self):
    n_tiles = len(self.track)
    if n_tiles <= 2 * self.start_clear_tiles + 1:
        return # 유효 구간 없음 → 스킵

    # 양끝 모두 제외 - 루프 트랙의 뒤쪽 끝도 시작선 인접
    candidates = list(range(self.start_clear_tiles,
                            n_tiles - self.start_clear_tiles)) # ← 핵심 수정
    self.np_random.shuffle(candidates)
    ...
```

3.3 로깅 무력화 — 벡터 env info 포맷 (세이핑 지표 전부 미기록)

- **증상:** 학습 TB 로그에 `penalties/mean_accel_turn`, `driving/mean_percent_off_track`, `driving/mean_obstacle_hits`, `rewards/mean_velocity` 가 **하나도 안 찍힘** (charts/losses만).
- **원인:** gymnasium 1.x 벡터 env의 `infos` 는 {키: (num_envs,) 배열} dict인데, 코드가 `infos.get(i)` (정수 인덱스)로 읽어 **항상 None** → 세이핑 지표 수집 블록 전체 스킵.
- **수정:** `infos[key][i]` 배열 인덱싱으로 교체(probe로 `'_final_info'` 없음 + 배열 포맷 확정). **검증:** 회전 + 가속 액션에서 `accel_turn` 10.8 정상 수집. → 이후 실험부터 지표 정상 기록.

이 세 버그(특히 3.3)는 “진단”의 전제였다. 3.3을 고치기 전 run들의 로그로는 코너 감속·이탈·충돌 추세를 알 수 없었고, 실제 진단은 모델을 직접 계측해서 했다(5절).


부록 Z — 그림 · 영상(GIF) 인덱스

Z.1 생성 그림 (figures)

모든 차트는 본문 실험 수치로 생성(`scripts/make_report_figs.py`). 파일은 `report_assets/` 에 있다.

- `fig_entropy_divergence.png` — entropy 발산(3-action ent0.01) vs 안정(2-action / 3-action ent0.003)
- `fig_reward_curve.png` — shaped 학습 곡선 2 vs 3 action
- `fig_clean_progression.png` — 장애물 clean 성능 진행 + 3-action
- `fig_2v3_grouped.png` — 2 vs 3 action clean 비교(Mean/Median/Min)
- `fig_corner_lever.png` — 코너 패널티 0.5→0.2 효과

Z.2 주행 프레임 (정지 컷)



장애물 회피 weaving — seed43, 보상 707



랜덤 크기 장애물 회피 — obs_small seed44, 보상 645



베이스 무장애물 주행 — seed46, 보상 838

Z.3 애니메이션 GIF (별도 첨부)

docx/PDF는 애니메이션을 표시하지 못하므로(첫 프레임만 정지), 아래 GIF 파일을 **별도로 열어** 동작을 확인할 것. 파일은 `report_assets/`에 있다. 원본 mp4는 각 `videos_*/` 폴더.

장면	GIF 파일	원본 mp4
베이스 주행 (r838)	<code>report_assets/gif_base_r838.gif</code>	<code>videos_2action_final/best_model_ep5_seed46_r838.mp4</code>
장애물 학습 전 충돌 (seed42, -68)	<code>report_assets/gif_before_seed42_r-68.gif</code>	<code>videos_obstacles_before/best_model_ep1_seed42_r-68.mp4</code>

장면	GIF 파일	원본 mp4
장애물 회피 (seed42, +323)	report_assets/gif_after_seed42_r323.gif	videos_obstacles_after/best_model_ep1_seed42_r323.mp4
장애물 회피 weaving (seed43, 707)	report_assets/gif_after_seed43_r707.gif	videos_obstacles_after/best_model_ep2_seed43_r707.mp4
랜덤크기 회피 (seed44, 645)	report_assets/gif_obs_small_r645.gif	videos_obs_small/best_model_ep3_seed44_r645.mp4